

CIÊNCIA DE DADOS

INTRODUÇÃO À CIÊNCIA DE DADOS

CENTRO FEDERAL DE EDUCAÇÃO
TECNOLOGICA DE MINAS GERAIS

MARCOS.EMILIANO@CEFETMG.BR
MARCOS EMILIANO

OBJETIVOS DA AULA

- Apresentar a Estrutura do Curso
- Apresentar os conceitos fundamentais da Ciência de Dados.
- Compreender a transição de dados brutos para conhecimento.
- Introduzir as plataformas e ferramentas analíticas que constituirão a base prática da disciplina.

INSTRUÇÕES INICIAIS

- Conteúdo Programático: Disponível no Github, no plano de ensino.
- Avaliações e Critérios: Frequência, participação, exercícios, projetos, provas.
- Material de Apoio: Livros, sites, e softwares disponibilizados no Moodle.

ESTRUTURA E EMENTA DA DISCIPLINA

Módulo 1:

- Introdução ao aprendizado de máquina
- Descoberta de conhecimento
- Pré-processamento e preparação de dados

ESTRUTURA E EMENTA DA DISCIPLINA

Módulo 2:

- Aprendizado não supervisionado
- Aprendizado supervisionado
- Avaliação da qualidade dos modelos
- Métricas de desempenho

AVALIAÇÕES

Distribuição das Notas

- Documentação Tema (11/09) → 20%
- Trabalho Prático 1 (15/10) → 40%
- Trabalho Prático 2 (27/11) → 40%

O QUE É A CIÊNCIA DE DADOS?

Definição formal: Campo **interdisciplinar** voltado à extração de **conhecimento** e **percepções** (insights) a partir de dados **estruturados** e não **estruturados**.

O QUE É A CIÊNCIA DE DADOS?

Interseção de disciplinas: Representa a convergência entre **matemática/estatística**, **ciência da computação** e conhecimento especializado do **domínio de aplicação** (ex: engenharia, metalurgia, negócios).

O QUE É A CIÊNCIA DE DADOS?

Foco metodológico: Utiliza métodos científicos, algoritmos de **aprendizado de máquina** e sistemas distribuídos para processamento analítico.

A IMPORTÂNCIA DA CIÊNCIA DE DADOS

Apoio à tomada de decisão: Permite a transição de decisões baseadas em **heurísticas** empíricas ou **intuição** para deliberações estritamente fundamentadas em **evidências**.

A IMPORTÂNCIA DA CIÊNCIA DE DADOS

Otimização e eficiência: Facilita a identificação de **gargalos**, modelagem de cenários **complexos** e melhoria contínua de **processos** industriais e de software.

A IMPORTÂNCIA DA CIÊNCIA DE DADOS

Capacidade preditiva: Habilita a **antecipação** de anomalias, **falhas** em sistemas e **tendências** comportamentais por meio da **generalização** de dados históricos.

PREVISÃO DO TEMPO

O problema meteorológico: A previsão moderna não é baseada em adivinhação, mas constitui um problema clássico e massivo de Ciência de Dados.

PREVISÃO DO TEMPO

Coleta em larga escala: Sensores, estações terrestres, radares e satélites geram continuamente terabytes de dados brutos sobre pressão atmosférica, temperatura e umidade.

PREVISÃO DO TEMPO

Modelagem matemática e preditiva:

Algoritmos complexos processam o histórico climático para simular a dinâmica da atmosfera, identificando padrões que permitem estimar a probabilidade de chuvas e tempestades com precisão científica.

COMO DADOS PODEM CONTER CONHECIMENTO?

Identificação de padrões ocultos: Algoritmos matemáticos são capazes de mapear **correlações e topologias** em espaços multidimensionais que escapam à observação humana direta.

COMO DADOS PODEM CONTER CONHECIMENTO?

**Cuidado, correlação não implica
causalidade!!!**

COMO DADOS PODEM CONTER CONHECIMENTO?

Associações espúrias: O fato de duas variáveis apresentarem comportamentos estatísticos semelhantes (crescerem ou decrescerem juntas) não significa que uma seja a causa da outra.


COMO DADOS PODEM CONTER CONHECIMENTO?

Variáveis de confusão: Frequentemente, um terceiro fator não observado (confounder) é o verdadeiro responsável por influenciar ambas as variáveis simultaneamente.

COMO DADOS PODEM CONTER CONHECIMENTO?

O papel do Cientista de Dados: Modelos de Machine Learning identificam **correlações matemáticas**, mas **não** compreendem a **lógica física** do problema. O **rigor científico** e o **conhecimento do domínio** são exigências inegociáveis para validar hipóteses causais.

Ice Cream Sales vs. Shark Attacks



COMO DADOS PODEM CONTER CONHECIMENTO?

Generalização indutiva: O conhecimento computacional emerge quando um modelo **infere** regras latentes a partir de uma **amostra** (treinamento) e consegue aplicá-las com precisão a dados **inéditos**.

PYTHON NOTEBOOKS

Notebooks são documentos dinâmicos que integram **código** executável, **textos** formatados, **equações** matemáticas e visualizações **gráficas** no mesmo ambiente.

GOOGLE COLAB

Trata-se de um ambiente Jupyter **Notebook** hospedado em **nuvem**, que **dispensa** configurações **locais** e gerenciamento de **dependências**.

IMPORTÂNCIA DO USO DE BIBLIOTECAS

Eficiência e padronização: O uso de bibliotecas evita a **reimplementação** de algoritmos complexos, garantindo o uso de código **testado** e **otimizado** pela comunidade científica.

PRINCIPAIS BIBLIOTECAS

NumPy: Fundamental para computação científica e operações eficientes com matrizes e arrays multidimensionais.

PANDAS

Pandas: Essencial para manipulação, limpeza e análise de estruturas de dados tabulares (DataFrames).

MATPLOTLIB E SEABORN

Matplotlib e Seaborn: Ferramentas para a geração de visualizações gráficas e exploração estatística visual.

SCIKIT-LEARN

Scikit-Learn: Principal framework para implementação padronizada de algoritmos de aprendizado de máquina e avaliação de modelos.

PLATAFORMA KAGGLE

É a maior plataforma colaborativa mundial dedicada a cientistas de dados e praticantes de aprendizado de máquina.

PLATAFORMA KAGGLE

Fornece acesso direto a milhares de conjuntos de dados (datasets) públicos e curados, abrangendo os mais diversos domínios do conhecimento.

PLATAFORMA KAGGLE

Oferece competições de modelagem preditiva, discussões técnicas e uma vasta biblioteca de notebooks públicos que demonstram implementações do estado-da-arte para resolução de problemas analíticos.

DÚVIDAS???