

CIÊNCIA DE DADOS

APRENDIZADO DE MÁQUINA

CENTRO FEDERAL DE EDUCAÇÃO
TECNOLOGICA DE MINAS GERAIS

MARCOS.EMILIANO@CEFETMG.BR
MARCOS EMILIANO

OBJETIVOS DA AULA

- Compreender a mudança de programação **clássica** para a baseada em **dados**.
- Diferenciar aprendizado **supervisionado** e não **supervisionado**.
- Demonstrar, de forma **prática**, como **dados** brutos geram **inferências**.
- Apresentar os principais frameworks em Python utilizados no ecossistema de dados.

O QUE É APRENDIZADO DE MÁQUINA?

Definição:

É uma **subárea** da **Inteligência Artificial** que fornece aos sistemas a habilidade de **aprender e melhorar** automaticamente a partir da **experiência**, sem serem **explicitamente** programados.

O QUE É APRENDIZADO DE MÁQUINA?

Como funciona? Em vez de escrever **regras** (condicionais if/else) para cada situação, fornecemos **exemplos** (dados) ao algoritmo.

O QUE É APRENDIZADO DE MÁQUINA?

○ **Modelo:**

○ **algoritmo** encontra **padrões** matemáticos nestes exemplos e cria um "**modelo**" capaz de tomar **decisões** sobre dados novos.

MUDANÇA DE PARADIGMA

- **Programação Tradicional:** Dados + Regras (Código criado pelo programador) -> Computador -> Respostas (Saídas)
- **Aprendizado de Máquina:** Dados + Respostas (Exemplos históricos) -> Computador -> Regras (Modelo Treinado)

Uma vez que o modelo gera as **regras**, podemos usá-lo para **prever** as respostas de dados que o computador **nunca** viu.

O QUE É UMA INFERÊNCIA?

Inferir não é "chutar": Enquanto um **chute** é uma tentativa **aleatória** sem **base lógica**, a **inferência** é uma **predição** rigorosamente **calculada**.

O QUE É UMA INFERÊNCIA?

Base Matemática: O modelo utiliza **estatística** e **padrões** extraídos dos dados de treinamento para **calcular** a resposta mais **provável** para um cenário inédito.

O QUE É UMA INFERÊNCIA?

Grau de Confiança:

Toda **inferência** é acompanhada de uma **probabilidade**. O modelo não **afirma** "vai acontecer X ", mas sim "existe **90%** de **probabilidade** de ser X , dado o **histórico analisado**".

O PERIGO DO VIÉS (BIAS) NOS MODELOS

A máquina não tem moralidade:
Algoritmos não distinguem o que é **ético** do que não é; eles apenas **reproduzem** e **automatizam** as lógicas presentes nos dados.

O PERIGO DO VIÉS (BIAS) NOS MODELOS

Herança de preconceitos:

Se os **dados históricos** contiverem decisões **enviesadas** (ex: histórico de contratações que favorece um **gênero** específico), o modelo aprenderá essa **discriminação** como uma **regra matemática** válida.

O PERIGO DO VIÉS (BIAS) NOS MODELOS

Responsabilidade do Cientista de Dados:
É essencial **auditar** os dados antes do
treinamento para garantir **representatividade**
e **justiça**, evitando a construção de sistemas
que perpetuem **desigualdades** sob o disfarce
da **neutralidade tecnológica**.

APRENDIZADO SUPERVISIONADO

- O algoritmo **aprende** a partir de dados **rotulados**.
- Isso significa que, para cada **exemplo** de entrada (**características**), nós fornecemos a saída correta (**resposta**).

APRENDIZADO SUPERVISIONADO

Subcategorias:

- **Classificação**: Prever **categorias** (Ex: Rótulo é "Aprovado" ou "Reprovado").
- **Regressão**: Prever valores **contínuos** (Ex: Rótulo é um preço em Reais).

INFERÊNCIA SUPERVISIONADA (CLASSIFICAÇÃO)

Problema: Aprovação automática de crédito bancário.

Renda	Idade	Dívida Ativa	Rótulo
1500	22	Sim	Negado
8000	45	Não	Aprovado
3200	35	Não	Aprovado
2100	25	Sim	???????

PRÁTICA: INFERÊNCIA SUPERVISIONADA (CLASSIFICAÇÃO)

Lógica do Modelo:

Ao analisar os **exemplos**, o algoritmo **aprende** que a presença de "**Dívida Ativa**" associada a uma "**Renda menor**" resulta em **negação**.

Logo, para o novo cliente, a inferência será **Negado**.

INFERÊNCIA SUPERVISIONADA (REGRESSÃO)

Problema: Prever o valor de venda de um imóvel.

Área	Quartos	D. Centro (KM)	Valor
50	1	15	150K
120	3	2	600K
80	2	10	320K
75	2	8	???????

INFERÊNCIA SUPERVISIONADA (REGRESSÃO)

Lógica do Modelo:

O algoritmo entende que o preço é diretamente proporcional à área/quartos e inversamente proporcional à distância do centro. A inferência gerará um valor contínuo, estimado em torno de R\$ 350.000.

APRENDIZADO NÃO SUPERVISIONADO

- O algoritmo trabalha com dados **não rotulados**. Não há uma "**resposta certa**" fornecida previamente.
- **Objetivo: Explorar** a estrutura oculta dos dados para extrair **conhecimento**.

APRENDIZADO NÃO SUPERVISIONADO

Principal técnica: Clustering (Agrupamento).

- O algoritmo **aproxima** elementos que possuem **características** matemáticas **semelhantes** e afasta os **diferentes**.

INFERÊNCIA NÃO SUPERVISIONADA (AGRUPAMENTO)

Problema: Segmentação de clientes para marketing (sem categorias prévias).

ID	VisitasMes	GastoMédio	Inferência
C1	2	45	Grupo A
C2	18	1200	Grupo B
C3	1	30	Grupo C
C4	15	950	Grupo D

INFERÊNCIA NÃO SUPERVISIONADA (AGRUPAMENTO)

Lógica do Modelo:

O sistema agrupou os dados baseado na **semelhança**. Nós, humanos, interpretamos a inferência: O **Grupo A** são clientes esporádicos; o **Grupo B** são clientes fiéis de alto valor.

DÚVIDAS???