

CIÊNCIA DE DADOS

PREPARAÇÃO DE DADOS PARA APRENDIZADO DE MÁQUINA

CENTRO FEDERAL DE EDUCAÇÃO
TECNOLOGICA DE MINAS GERAIS

MARCOS.EMILIANO@CEFETMG.BR
MARCOS EMILIANO

OBJETIVOS DA AULA

- **Revisar** os conceitos de estatística (Média, Mediana, Moda, Quartis, Desvio Padrão).
- **Compreender** as técnicas de **detecção** de **anomalias** estatísticas (IQR e Z-score).
- **Apresentar** estratégias de **tratamento** de valores **ausentes** e **discrepantes** (outliers).
- **Demonstrar** as técnicas de **transformação** de dados para a **modelagem** (Encoding e Scaling).

NOÇÕES BÁSICAS DE ESTATÍSTICA: MÉDIA (MEAN)

Definição: É a soma de **todos** os valores de um conjunto **dividida** pelo número **total** de observações. É a medida de **tendência central** mais comum.

Sensibilidade: A média é **altamente** influenciada por valores extremos (outliers).

NOÇÕES BÁSICAS DE ESTATÍSTICA: MÉDIA (MEAN)

Exemplo Prático:

Um estagiário anotou o tempo de resposta de um servidor em milissegundos durante 5 acessos: [12, 15, 14, 16, 13].

Cálculo: $(12 + 15 + 14 + 16 + 13) / 5 = 14$ ms.

NOÇÕES BÁSICAS DE ESTATÍSTICA:

MEDIANA (MEDIAN)

Definição: É o valor que separa a metade superior da metade inferior de um conjunto de dados ordenado. Se houver um número par de observações, é a média dos dois valores centrais.

Vantagem: É robusta contra valores extremos, representando melhor o "centro" em dados assimétricos.

NOÇÕES BÁSICAS DE ESTATÍSTICA: MEDIANA (MEDIAN)

Exemplo Prático: Salários em uma pequena startup: [RS 2.000, RS 2.500, RS 3.000, RS 3.500, RS 50.000 (Diretor)].

Análise: A média salarial é RS 12.200 (irreal para a maioria). A mediana é RS 3.000, refletindo a realidade com mais precisão.

NOÇÕES BÁSICAS DE ESTATÍSTICA: MODA (MODE)

Definição: É o valor (ou valores) que ocorre com maior frequência em um conjunto de dados.

Aplicação: Muito útil para variáveis categóricas (texto) onde não é possível calcular médias.

NOÇÕES BÁSICAS DE ESTATÍSTICA: MODA (MODE)

Exemplo Prático: Identificação de falhas em peças metalúrgicas. Tipos de falha reportados na semana: ["Fissura", "Desgaste", "Fissura", "Quebra", "Fissura"].

Resultado: A moda é "**Fissura**". Pode existir mais de uma moda (bimodal ou multimodal) se múltiplas categorias empatarem na liderança.

PERCENTIS E QUARTIS

Definição (Percentil):

Valor abaixo do qual cai uma determinada porcentagem das **observações**. (Ex: O percentil 90 indica que o valor é maior que 90% da amostra).

PERCENTIS E QUARTIS

Definição (**Quartis**): São os três **percentis** que **dividem** os dados ordenados em **quatro partes iguais** (25% cada).

- Q1 (Primeiro Quartil): 25° percentil.
- Q2 (Segundo Quartil): 50° percentil (exatamente a Mediana).
- Q3 (Terceiro Quartil): 75° percentil.

PERCENTIS E QUARTIS

Exemplo:

Se o **Q3** do tempo de entrega de um e-commerce é de **4** dias, significa que **75%** das entregas são concluídas em **até** 4 dias, e apenas 25% demoram **mais** que 4 dias.

DESVIO PADRÃO

Definição:

Quantifica a **variabilidade** (ou **dispersão**) **média** dos dados em relação à sua **própria média aritmética**.

$$S = \sqrt{ \left[\Sigma (x_i - \text{média})^2 / (n - 1) \right]}$$

DESVIO PADRÃO

Como calcular (Passo a Passo):

1. Encontre a **Média** do conjunto de dados.
2. **Subtraia** a **média** de cada valor **individual** e eleve o resultado ao **quadrado**.
3. **Some** todos esses resultados quadrados.
4. Divida essa soma pela **quantidade total** de dados menos **um** ($n - 1$). O resultado é a **Variância**.
5. Calcule a **raiz quadrada** da **Variância** para encontrar o **Desvio Padrão**.

DESVIO PADRÃO

Amostra do comprimento de 5 hastes metálicas (em cm): $[48, 49, 50, 51, 52]$.

- Média: 50 cm.
- Delta de cada ponto até a média ao quadrado: $[(-2)^2, (-1)^2, 0^2, 1^2, 2^2] = [4, 1, 0, 1, 4]$. Soma = 10.
- Variância Amostral = $10 / (5 - 1) = 2,5$.
- Desvio Padrão = $\text{Raiz}(2,5) \approx 1,58$ cm.

Interpretação: Os cortes desviam, em média, 1,58 cm do comprimento central.

POR QUE O TRATAMENTO DE DADOS É NECESSÁRIO?

Algoritmos são estritos:

Modelos matemáticos de Machine Learning (como Scikit-Learn) não aceitam campos vazios (NaN) ou texto puro na matriz de cálculo.

POR QUE O TRATAMENTO DE DADOS É NECESSÁRIO?

Princípio GIGO (Garbage In, Garbage Out):
A **qualidade** das **predições** de um modelo **nunca** será superior à **qualidade** dos **dados** fornecidos para treiná-lo.

POR QUE O TRATAMENTO DE DADOS É NECESSÁRIO?

O Papel do Cientista:

Cerca de 70% a 80% do tempo de um projeto de Ciência de Dados é gasto na **limpeza** e **preparação**, não no **treinamento** do algoritmo.

TRATAMENTO DE DADOS: VALORES AUSENTES

O problema: **Falhas** em sensores, **erros** de digitação ou campos **opcionais** deixam "buracos" no dataset.

- **Estratégia 1:** Remoção (Drop). **Excluir** a linha inteira. Recomendado apenas quando a **quantidade** de dados **ausentes** é **insignificante** (ex: 1% do dataset) e a base é grande.

TRATAMENTO DE DADOS: VALORES AUSENTES

Estratégia 2: Imputação (Fill). **Preencher** o vazio com **estatísticas** seguras.

- Usar a **Média**: Se os dados forem simétricos e sem outliers.
- Usar a **Mediana**: Se os dados possuírem valores extremos.
- Usar a **Moda**: Exclusivo para preencher valores ausentes em colunas de texto (categóricas).

TRATAMENTO DE DADOS: LIDANDO COM OUTLIERS

O problema:

Valores **atípicos** (como o salário de R\$ 50.000 do exemplo da Mediana) forçam a linha de aprendizado de algoritmos de **regressão** para fora do **padrão real**.

TRATAMENTO DE DADOS: LIDANDO COM OUTLIERS

Identificação:


Utiliza-se a **amplitude interquartil** ($IQR = Q3 - Q1$). Valores abaixo de $(Q1 - 1.5 * IQR)$ ou acima de $(Q3 + 1.5 * IQR)$ são **estatisticamente** considerados **outliers**.

AMPLITUDE INTERQUARTIL


Amplitude Interquartil (IQR – Interquartile Range) é uma **medida de dispersão** estatística que avalia a **variabilidade dos dados**.

Ao subtrair o **Primeiro Quartil** ($Q1$) do **Terceiro Quartil** ($Q3$), o IQR **ignora as extremidades**, tornando-se uma métrica extremamente robusta contra **valores atípicos**.

AMPLITUDE INTERQUARTIL



AMPLITUDE INTERQUARTIL



AMPLITUDE INTERQUARTIL

O cálculo principal para **detecção** de **outliers** utiliza o método de Tukey, que estabelece **limites operacionais** (cercas) ao redor da **concentração** principal dos dados:

- $IQR = Q3 - Q1$
- Limite Inferior (LI) = $Q1 - (1,5 * IQR)$
- Limite Superior (LS) = $Q3 + (1,5 * IQR)$

AMPLITUDE INTERQUARTIL

Qualquer valor que caia **abaixo** do **Limite Inferior** ou **acima** do **Limite Superior** é **matematicamente** classificado como um **outlier**.

AMPLITUDE INTERQUARTIL

Exemplo:

Considere os tempos (em minutos) de processamento de 9 lotes de peças:

[10, 12, 14, 15, 16, 18, 20, 22, 55]

1. Encontrando os Quartis:

- A **Mediana** (Q2) é 16 (o **valor central**).
- O **Q1** (**mediana da primeira metade** [10, 12, 14, 15]) é: $(12 + 14) / 2 = 13$.
- O **Q3** (**mediana da segunda metade** [18, 20, 22, 55]) é: $(20 + 22) / 2 = 21$.

AMPLITUDE INTERQUARTIL

Calculando o IQR:

- $IQR = Q3 - Q1 = 21 - 13 = 8.$

Definindo os Limites:

- Limite Inferior = $13 - (1,5 * 8) = 13 - 12 = 1.$
- Limite Superior = $21 + (1,5 * 8) = 21 + 12 = 33.$

AMPLITUDE INTERQUARTIL

Conclusão do IQR:

O tempo de processamento de **55** minutos ultrapassa o **limite superior** estabelecido de 33 minutos. **Portanto**, é estatisticamente classificado como um **outlier** e deve ser **investigado** ou **removido** antes do treinamento do modelo.

O USO DO Z-SCORE (ESCORE PADRÃO)

O Z-score é uma **métrica estatística** paramétrica que quantifica a **distância** de um ponto de dado em relação à **média** do conjunto, medida em unidades de **Desvio Padrão**.

A equação fundamental é:

$$Z = (\text{Valor} - \text{Média}) / \text{Desvio Padrão}$$

O USO DO Z-SCORE (ESCORE PADRÃO)

Diferente do IQR, que é baseado em **medidas de posição** (medianas), o Z-score pressupõe que os dados seguem uma **Distribuição Normal** (a clássica **curva** de **sino** estatística). Em uma distribuição perfeitamente normal:

- 68% dos dados entre $Z = -1$ e $Z = 1$.
- 95% dos dados entre $Z = -2$ e $Z = 2$.
- 99,7% dos dados entre $Z = -3$ e $Z = 3$.

O USO DO Z-SCORE (ESCORE PADRÃO)

Regra de Detecção:

Na **preparação** de dados para aprendizado de máquina, convencionou-se que qualquer registro com um Z-score **absoluto** maior que **3** (ou seja, $Z > 3$ ou $Z < -3$) encontra-se na **cauda** extrema da distribuição, sendo considerado um **outlier**.

IQR VS Z-SCORE

Utilize o **IQR** quando a distribuição dos seus dados for **assimétrica** ou quando existirem **outliers extremos e frequentes**. Por ser baseado em **quartis**, o cálculo do **IQR** não é corrompido pelos próprios valores **atípicos**.

IQR VS Z-SCORE

Utilize o **Z-score** quando os dados apresentarem um comportamento **Gaussiano** (distribuição **normal**).

É necessário cautela, se a base de dados possuir **anomalias** de magnitude muito **elevada**, a **Média** e o **Desvio Padrão** originais serão **distorcidos**, o que **mascara** os **outliers** e compromete o **cálculo** do próprio Z-score.

TRATAMENTO DE DADOS: LIDANDO COM OUTLIERS

Ação:

Dependendo do **contexto**, os outliers são **removidos** (se forem **erros** de medição) ou **limitados** a um **teto** máximo aceitável para não **distorcer** o modelo.

PREPARAÇÃO DE DADOS: CODIFICAÇÃO CATEGÓRICA (ENCODING)

O problema: Como ensinar o **algoritmo** a ler variáveis de **texto** como "Cor" ou "Tamanho"?

Label Encoding (Codificação Ordinal): Usado quando há hierarquia. Ex: Tamanho ["Pequeno", "Médio", "Grande"] vira [0, 1, 2].

PREPARAÇÃO DE DADOS: CODIFICAÇÃO CATEGÓRICA (ENCODING)

One-Hot Encoding (Variáveis Dummy):
Usado quando **não há hierarquia**, para **evitar** que o **modelo** ache que uma categoria "**vale mais**" que a outra.

Exemplo: "Cor da Peça". Em vez de usar [1=Azul, 2=Vermelho], criam-se novas **colunas** binárias (0 ou 1): [É_Azul?], [É_Vermelho?].

PREPARAÇÃO DE DADOS: ESCALONAMENTO NUMÉRICO (SCALING)

O problema:

Modelos baseados em **cálculo de distância** (como k-NN) dão mais **peso** a colunas com **números maiores**. Uma coluna "**Salário**" (ex: 5000) **ofuscaria** completamente a coluna "**Idade**" (ex: 30).

PREPARAÇÃO DE DADOS: ESCALONAMENTO NUMÉRICO (SCALING)

Normalização (MinMaxScaler):

Comprime todos os valores da coluna para um **intervalo** entre **0 e 1**, mantendo a **proporção** exata entre eles.

PREPARAÇÃO DE DADOS: ESCALONAMENTO NUMÉRICO (SCALING)

Padronização (StandardScaler):

Centraliza os dados na **média zero** e ajusta o **desvio padrão** para 1. Essencial para algoritmos de **Regressão Linear**, **Regressão Logística** e **Redes Neurais**.

DÚVIDAS???