

CIÊNCIA DE DADOS

MODELOS DE CLASSIFICAÇÃO PARTE 01

CENTRO FEDERAL DE EDUCAÇÃO
TECNOLOGICA DE MINAS GERAIS

MARCOS.EMILIANO@CEFETMG.BR
MARCOS EMILIANO

OBJETIVOS DA AULA

- Relembrar os **tipos** de **problemas** em Aprendizado de Máquina.
- **Definir** o que caracteriza um **problema de Classificação**.
- Entender os rudimentos de como os **modelos** traçam "**fronteiras de decisão**".
- **Explorar** o funcionamento **intuitivo** e **prático** de dois modelos fundamentais: **k-NN** e **Árvores de Decisão**.

TIPOS DE PROBLEMAS EM MACHINE LEARNING

Aprendizado Supervisionado:

O modelo **aprende** com **dados** que já possuem a "**resposta certa**" (**rótulos**).

- **Regressão**: Prevê um **valor** contínuo (Ex: Preço de uma casa, Temperatura).
- **Classificação**: Prevê uma **categoria** (Ex: É fraude ou não? Aprovado ou Reprovado?).

TIPOS DE PROBLEMAS EM MACHINE LEARNING

Aprendizado Não Supervisionado:

O modelo busca padrões em dados **sem rótulos**.

- **Agrupamento** (Clustering): **Junta** dados **similares** (Ex: Segmentação de clientes).

MODELOS DE CLASSIFICAÇÃO

Definição:

A **classificação** é a tarefa de **prever** a qual **classe** (ou categoria) um dado **pertence**, com base em suas **características** (features).

MODELOS DE CLASSIFICAÇÃO

Exemplos do Mundo Real:

- **Filtro de Spam:** Classificar um e-mail como "Spam" ou "Não Spam" (Classificação Binária).
- **Diagnóstico Médico:** Classificar um tumor como "Benigno" ou "Maligno".
- **Reconhecimento de Imagem:** Identificar se a foto é de um "Cachorro", "Gato" ou "Pássaro" (Classificação Multiclasse).

MODELOS DE CLASSIFICAÇÃO


Como um Modelo "**Aprende**" a **Classificar**?

○ **Espaço de Características** (Feature Space): Imagine um gráfico onde cada eixo é uma característica do dado (ex: Eixo X = Idade, Eixo Y = Renda, etc).


MODELOS DE CLASSIFICAÇÃO

Como um Modelo "**Aprende**" a **Classificar**?

Os Pontos: Cada **registro** histórico é um **ponto** nesse **gráfico**, pintado com a cor da sua **classe** (Ex: Verde = Aprovado, Vermelho = Reprovado).



Best Features




MODELOS DE CLASSIFICAÇÃO


Como um Modelo "**Aprende**" a **Classificar**?

A Fronteira de Decisão: O objetivo de **QUALQUER** algoritmo de **classificação** é desenhar uma "**linha**" (matemática) que separe os **pontos verdes** dos **vermelhos** da **melhor forma possível**. Quando um dado novo chega, o modelo verifica de qual lado da linha ele caiu.


Linear Decision Boundary



MODELOS DE CLASSIFICAÇÃO



Como definir a
Fronteira de
Decisão para o
caso ao lado?



K-NEAREST NEIGHBORS (K-NN)

O Vizinho Mais Próximo: É um dos algoritmos mais **simples** e **intuitivos**. Ele não tenta **desenhar** uma **linha** matemática **complexa**.

K-NEAREST NEIGHBORS (K-NN)

Como funciona:

Quando um dado **novo** precisa ser **classificado**, o **k-NN** olha para os **exemplos históricos** que estão **geometricamente** mais **próximos** dele no "**Feature Space**".

K-NEAREST NEIGHBORS (K-NN)

A regra é a Similaridade:

"Diga-me com quem andas e te direi quem és." Se os **K** dados **mais parecidos** com o **novo registro** pertencem à Classe **A**, o **novo registro provavelmente** também é da Classe **A**.

K-NN NA PRÁTICA:

Problema: Prever se um cliente de e-commerce é um "Comprador Frequente".

Cliente	Acessos no Mês	Tempo no Site	Classe (É Frequente?)
A	2	5	Não
B	20	45	Sim
C	18	40	Sim
Novo	19	42	Inferência: ?

K-NN NA PRÁTICA

Lógica do algoritmo (com $k = 3$):

1. O **k-NN** calcula a **distância matemática** do **Novo** Cliente para os antigos A, B e C.
2. O **Novo** Cliente (**19** acessos, **42** min) está muito **próximo** de B e C, e muito **distante** de A.
3. Os **3** vizinhos "votam": **2** votos para "Sim" (B e C) e **1** voto para "Não" (A).
4. **Resultado**: O modelo classifica o Novo Cliente como "**Sim**".

O PAPEL DO "K" NO K-NN

O que é o "**k**"? É o **número de vizinhos** que o algoritmo vai **consultar** para tomar a **decisão** (a quantidade de votos).

Regra prática: Geralmente, escolhemos valores **ímpares** ($k=3, 5, 7$) para evitar **empates** em classificações binárias (Sim/Não).

O PAPEL DO "K" NO K-NN

Cuidado com o valor de k:

- $k = 1$: O modelo confia **cegamente** em um **único** vizinho (muito **sensível** a anomalias/outliers).
- k muito **grande**: O modelo começa a consultar vizinhos muito **distantes**, **perdendo** a noção de **similaridade local**.

ÁRVORE DE DECISÃO (DECISION TREE)

Dividir para Conquistar:


Diferente do k-NN que usa **distâncias** geométricas, a Árvore de Decisão usa **lógica** pura e **regras** de corte.

ÁRVORE DE DECISÃO (DECISION TREE)

Como funciona: O algoritmo faz uma série de **perguntas** de "**Sim** ou **Não**" baseadas nas **características** dos **dados**. Cada resposta divide a **base** em **grupos menores**, até chegar a uma **conclusão** final.



Analogia: Funciona como o jogo de tabuleiro "**Cara a Cara**".

ÁRVORE DE DECISÃO




ÁRVORE DE DECISÃO

Predictors				Target
Outlook	Temp.	Humidity	Windy	Play Golf
Rainy	Hot	High	False	No
Rainy	Hot	High	True	No
Overcast	Hot	High	False	Yes
Sunny	Mild	High	False	Yes
Sunny	Cool	Normal	False	Yes
Sunny	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Rainy	Mild	High	False	No
Rainy	Cool	Normal	False	Yes
Sunny	Mild	Normal	False	Yes
Rainy	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Sunny	Mild	High	True	No



How To CHOOSE THE PERFECT BOARD GAME





ÁRVORE DE DECISÃO NA PRÁTICA

Problema: Prever aprovação de crédito bancário automático.

Cliente	Renda (R\$)	Dívida Ativa?	Classe (Crédito)
A	1.500	Sim	Negado
B	4.000	Sim	Negado
C	5.000	Não	Aprovado
Novo	6.000	Não	Inferência: ?

ÁRVORE DE DECISÃO NA PRÁTICA

A Árvore gerada pelo algoritmo:

- Pergunta 1 (Nó Raiz): A Renda é menor que RS 2.000?
 - -> Se SIM: Negado.
 - -> Se NÃO: Vai para a próxima pergunta.
- Pergunta 2 (Nó Interno): O cliente tem Dívida Ativa?
 - -> Se SIM: Negado.
 - -> Se NÃO: Aprovado (Folha).

ÁRVORE DE DECISÃO NA PRÁTICA

A Árvore gerada pelo algoritmo:

- Lógica para o Novo Cliente:
 - Renda < 2000? (Não).
 - Tem Dívida? (Não).
 - Resultado = Aprovado.

VANTAGENS E DESVANTAGENS DA ÁRVORE

Vantagem Principal (Interpretabilidade):

É um modelo "**Caixa Branca**". Nós, humanos, conseguimos **olhar** para o **fluxograma** gerado e **entender** e **explicar** exatamente por que o algoritmo **aprovou** ou **negou** o crédito.

VANTAGENS E DESVANTAGENS DA ÁRVORE

Desvantagem Principal (Overfitting):

Se deixarmos a árvore **crescer sem limites**, ela fará tantas **perguntas** que acabará "**decorando**" os **dados de treinamento**, criando **regras absurdas** que **falham** no mundo real.

DÚVIDAS???