

CIÊNCIA DE DADOS

MODELOS DE CLASSIFICAÇÃO PARTE 02

CENTRO FEDERAL DE EDUCAÇÃO
TECNOLOGICA DE MINAS GERAIS

MARCOS.EMILIANO@CEFETMG.BR
MARCOS EMILIANO

OBJETIVOS DA AULA

- **Entender** as **limitações** dos **modelos simples** vistos na Parte 01.
- **Conhecer** o modelo **Naive Bayes** e como a **probabilidade** resolve problemas de **texto**.
- **Desmistificar** a **Regressão Logística** como um **classificador** baseado em **porcentagem**.
- **Aprender** o conceito de "**Ensemble**" e como o **Random Forest corrige** os erros das **Árvores de Decisão**.

POR QUE PRECISAMOS DE MODELOS MELHORES?

O problema do k-NN:

Para classificar um **único** dado novo, ele precisa calcular a **distância** matemática para **TODOS** os milhões de registros do histórico. Em bancos de dados **gigantes** (Big Data), ele se torna **extremamente lento**.

POR QUE PRECISAMOS DE MODELOS MELHORES?

O problema da Árvore de Decisão:

Ela tem **memória fotográfica**. Se deixarmos, ela cria tantas **perguntas** específicas que acaba "**decorando**" o passado (**Overfitting**).

Quando vê um dado **novo** na **vida real**, ela **erra** feio porque as **regras** ficaram **complexas demais**.

NAIVE BAYES (O PROBABILÍSTICO)

O que é?

Um modelo baseado puramente em **probabilidade** (Teorema de Bayes). Ele calcula a **chance** de um evento **ocorrer** dado que outro evento **já ocorreu**.

O TEOREMA DE BAYES

Uma **equação matemática** que descreve a **probabilidade** de um **evento**, baseada em **conhecimentos a priori** que **podem** estar **relacionados** a esse **evento**.

O TEOREMA DE BAYES

A Equação:

$$P(\text{Classe} \mid \text{Dados}) = \frac{[P(\text{Dados} \mid \text{Classe}) * P(\text{Classe})]}{P(\text{Dados})}$$

O que cada termo significa:

- $P(\text{Classe})$: **Probabilidade "a priori"**. A chance **geral** da classe **existir antes** de vermos **qualquer** dado (ex: 20% dos e-mails no mundo são Spam).

O TEOREMA DE BAYES

A Equação:

$$P(\text{Classe} \mid \text{Dados}) = \frac{[P(\text{Dados} \mid \text{Classe}) * P(\text{Classe})]}{P(\text{Dados})}$$

O que cada termo significa:

- $P(\text{Dados} \mid \text{Classe})$: **Verossimilhança** (Likelihood). Se eu **SEI** que é Spam, qual a chance de conter a palavra "**Oferta**"?

O TEOREMA DE BAYES

A Equação:

$$P(\text{Classe} \mid \text{Dados}) = \frac{[P(\text{Dados} \mid \text{Classe}) * P(\text{Classe})]}{P(\text{Dados})}$$

O que cada termo significa:

- $P(\text{Classe} \mid \text{Dados})$: **Probabilidade "a posteriori"**. A nossa **Inferência** final. Qual a chance de ser **Spam**, **DADO QUE** eu vi a palavra "**Oferta**"?

NAIVE BAYES (O PROBABILÍSTICO)

O termo "Naive" (Ingênuo):

O modelo **assume** ingenuamente que **todas** as **características** do dado são **completamente independentes** umas das outras.

NAIVE BAYES (O PROBABILÍSTICO)

Melhor Caso de Uso:

Funciona muito bem para **classificação de textos**, como **análise de sentimentos** (Positivo/Negativo) e filtros de **Spam**. Além disso, é rápido.

NAIVE BAYES NA PRÁTICA

Problema: Filtro automático de E-mail (Spam ou Não Spam).

Histórico de e-mails recebidos:

1. "Oferta de empréstimo urgente" -> SPAM
2. "Relatório do projeto" -> NÃO SPAM
3. "Oferta: compre agora" -> SPAM

Chega um Novo E-mail:

1. "Oferta de projeto" -> Inferência: ?

NAIVE BAYES NA PRÁTICA

Lógica do Algoritmo (usando Bayes):

1. O algoritmo **quebra** o **texto**: "Oferta" e "projeto".
2. Ele **calcula**: Qual a **probabilidade** da classe **SPAM** dado que tem "**Oferta**" E "**projeto**"?
3. "**Oferta**" puxa a probabilidade do termo $P(\text{Dados}|\text{Classe})$ **fortemente** para **SPAM**. "projeto" **puxa** para **NÃO SPAM**.
4. O modelo multiplica as **probabilidades** marginais e descobre **matematicamente** qual lado tem o maior peso (ex: 66% de chance final de ser SPAM).

REGRESSÃO LOGÍSTICA

O Nome Engana:


Apesar de ter a palavra "**Regressão**" no nome, este é um dos algoritmos de **CLASSIFICAÇÃO** mais utilizados no **mercado financeiro** e na área da **saúde**.

REGRESSÃO LOGÍSTICA

Como funciona?

Ele pega qualquer valor **numérico** de **entrada** e o passa por uma **função** matemática chamada "Curva **Sigmoide**" (que tem o formato da letra S).

REGRESSÃO LOGÍSTICA



REGRESSÃO LOGÍSTICA

O Funcionamento da Sigmoide:

Ela normaliza, "ajusta", qualquer número para que ele caia obrigatoriamente em um intervalo entre 0 e 1 (ou seja, de 0% a 100%).

REGRESSÃO LOGÍSTICA NA PRÁTICA

Problema: Prever falha em um motor metalúrgico baseado na temperatura.

REGRESSÃO LOGÍSTICA NA PRÁTICA

Leitura	Temperatura (°C)	Classe (Falhou?)
A	50	Não (0)
B	60	Não (0)
C	90	Sim (1)
D	100	Sim (1)
Novo	75	Inferência: ?

REGRESSÃO LOGÍSTICA NA PRÁTICA

1. O modelo cria uma curva em forma de "**S**" que sobe do **0** para o **1** conforme a **temperatura** aumenta.
2. Inserimos o valor **75°C** na equação da curva.
3. A **equação** retorna o valor **0.70**.
4. **Interpretação**: O modelo afirma que há **70%** de chance de falha. Como **70%** é maior que o **ponto de corte** (50%), a inferência final é: **SIM** (Falha).

ENSEMBLE: A SABEDORIA DAS MULTIDÕES

A ideia central:

Se você perguntar o **peso** de um **boi** para um **único** agrônomo, ele pode **errar**. Mas se você perguntar para **1.000 estudantes** de **veterinária** e tirar a **média** das respostas, o resultado **tende** a ser mais próximo da **realidade**.

A MATEMÁTICA DO ENSEMBLE: 1 VS 100

O Dilema do Custo x Benefício:

Para fazer um **único algoritmo** passar de 70% de acerto para 90%, o custo pode ser alto a depender do problema. O modelo fica **pesado, consome** muita memória, exige **cálculos complexos** e pode acabar "decorando" (overfitting) para atingir esse resultado.

A MATEMÁTICA DO ENSEMBLE: 1 VS 100

O Teorema do Júri de Condorcet:

O que é matematicamente melhor?

- Opção A: 1 modelo que acerta 90% das vezes.
- Opção B: 100 modelos simples (weak learners) que acertam apenas 70% das vezes cada um.

A MATEMÁTICA DO ENSEMBLE: 1 VS 100

A Prova:

Se os 100 modelos errarem de **forma independente**, a chance da **maioria** (51 modelos) errar a **mesma** questão **simultaneamente** segue uma distribuição binomial e é inferior a 0,01%. Logo, a **Opção B** atinge quase 99,99% de **acerto** na prática, com modelos minúsculos, rápidos e que não decoram os dados.

ENSEMBLE: A SABEDORIA DAS MULTIDÕES

Em Machine Learning (Ensemble):
Em vez de treinar um **modelo complexo** que pode errar "sozinho", treinamos **dezenas de modelos simples** e pedimos para eles **votarem**. O **erro de um é compensado pelo acerto dos outros**.

RANDOM FOREST

O que é?

Uma **evolução** da **Árvore de Decisão**. Em vez de criar uma **única** árvore **gigante** que "**decora**" os dados, o algoritmo planta uma "**floresta**" com **centenas** de **árvores pequenas** e **diferentes**.

RANDOM FOREST

A Aleatoriedade (Random):

Para **garantir** que as árvores sejam **diferentes**, cada uma recebe apenas um **pedaço aleatório** dos **dados** e pode olhar apenas para algumas **colunas** (ex: uma olha só para a idade, outra só para a renda).

RANDOM FOREST

O Veredito:

Quando chega um dado **novo**, ele passa por **todas as árvores**. A **classe** que receber mais **votos** ganha. Isso acaba quase que totalmente com o problema do **Overfitting** (memorização).

RANDOM FOREST NA PRÁTICA

Problema: Aprovar empréstimo para um Novo Cliente.

A "Floresta" tem **3** árvores construídas com **partes diferentes dos dados.**

O Novo Cliente possui:

- Renda Alta
- Idade 22 anos
- Sem Dívidas.

RANDOM FOREST NA PRÁTICA

Lógica do Algoritmo (Votação):

- **Árvore 1:** (Só analisou **Renda** e **Idade**): Diz APROVADO (por causa da renda alta).
- **Árvore 2:** (Só analisou **Idade** e **Dívida**): Diz NEGADO (achou o cliente muito jovem).
- **Árvore 3:** (Só analisou **Renda** e **Dívida**): Diz APROVADO (sem dívidas e com renda).

RANDOM FOREST NA PRÁTICA

Lógica do Algoritmo (Votação):

- Apuração dos votos: **2** votos para **Aprovado** vs 1 voto para **Negado**.
- **Resultado Final: APROVADO**. A falha de julgamento isolada da Árvore 2 foi **neutralizada** pela maioria.

DÚVIDAS???