

CIÊNCIA DE DADOS

MODELOS DE REGRESSÃO: PREVENDO VALORES CONTÍNUOS

CENTRO FEDERAL DE EDUCAÇÃO
TECNOLOGICA DE MINAS GERAIS

MARCOS.EMILIANO@CEFETMG.BR
MARCOS EMILIANO

OBJETIVOS DA AULA

- O que é um problema de **regressão**?
- **Diferenças e semelhanças** entre **Classificação** e **Regressão**.
- **Regressão** Linear **Simple**s e **Múltipla**.
- Modelos baseados em vizinhança e árvores: **KNN**, **Árvore de Decisão** e **Random Forest**.

O QUE É UM PROBLEMA DE REGRESSÃO?

Ocorre quando o **objetivo** do modelo é **prever** um **valor numérico contínuo**.

Infinitas Possibilidades: Em vez de escolher uma categoria fixa, o modelo estima um número dentro de uma escala contínua.

O QUE É UM PROBLEMA DE REGRESSÃO?

Exemplos no Mundo Real:

- Estimativa do **preço** de **venda** de um imóvel (RS).
- Previsão da **temperatura** máxima de um **motor** ($^{\circ}\text{C}$).
- Cálculo do **tempo** restante até a **falha** de um equipamento (Horas).
- Medição do **consumo** de combustível de um **veículo** (km/L).

CLASSIFICAÇÃO VS. REGRESSÃO

A Mudança de Paradigma:

A **estrutura** do algoritmo e a **entrada** (X) continuam **semelhantes**, mas a **resposta** final (y) **muda**.

CLASSIFICAÇÃO VS. REGRESSÃO

Característica	Classificação	Regressão
Objetivo	Prever uma categoria ou classe.	Prever uma quantidade ou valor numérico.
Tipo de Saída	Discreta (ex.: "Sim/Não", "A/B/C").	Contínua (ex.: R\$ 250.000, 1.85 m, 32.5 °C).
Pergunta	"A qual grupo este dado pertence?"	"Qual é o valor exato estimado?"

CLASSIFICAÇÃO VS. REGRESSÃO

Exemplo Comparativo (Venda de Casas):

- **Classificação:** Prever se a casa será **vendida** por preço "**Alto**", "**Médio**" ou "**Baixo**".
- **Regressão:** Prever o valor **exato** de venda da casa (ex.: RS 452.300,00).

REGRESSÃO LINEAR SIMPLES

Traça a melhor **linha reta** que se ajusta aos **dados** para relacionar uma **variável** de **entrada** (x) a uma resposta (y).

- **Equação da Reta:** $y = b_0 + b_1 x$
- **b_0 :** Interseção (valor de y quando $x = 0$).
- **b_1 :** Inclinação (o quanto y muda para cada variação em x).

REGRESSÃO LINEAR SIMPLES

Entrada (x): Horas de teste de rodagem de um pneu.

Saída (y): Desgaste da borracha em milímetros.

Função encontrada: $\text{Desgaste}(x) = 0,5 + 0,02 \cdot x$

Uso prático: Se rodarmos 100 horas, a função transforma a entrada diretamente no valor:

$$0,5 + 0,02(100) = 2,5 \text{ mm.}$$

REGRESSÃO LINEAR SIMPLES

Histórico de Dados (Treinamento):

- x (Horas de uso da máquina): $[1, 2, 3]$
- y (Desgaste da peça em mm): $[3, 5, 7]$

REGRESSÃO LINEAR SIMPLES

Construção da Função:

1. Calculamos as médias: $x = 2, y = 5$.
2. Calculamos a inclinação: $b_1 = 2$ (o desgaste aumenta 2 mm a cada hora).
3. Calculamos o intercepto: $b_0 = 5 - (2 * 2) = 1$.

Função Gerada: $f(x) = 1 + 2x$


REGRESSÃO LINEAR SIMPLES

Inferência (Previsão para um Novo Dado):

Nova Pergunta: Qual será o desgaste de uma peça após 4 horas de uso ($x = 4$)?

Cálculo da Inferência: $f(4) = 1 + 2^*(4) = 9$ mm.

REGRESSÃO LINEAR SIMPLES



LIMITAÇÕES DA REGRESSÃO LINEAR SIMPLES

A Premissa da Causa Única:

Assumir que apenas **uma** variável (x) explica o comportamento de y é **irrealista** para a maioria dos **problemas complexos**

LIMITAÇÕES DA REGRESSÃO LINEAR SIMPLES

Rigidez da Linha Reta:

Fenômenos **reais raramente** são estritamente **lineares**. **Processos** que envolvem **saturação**, retornos **decrecentes** ou **crescimento** exponencial não podem ser bem representados por uma **reta única**.

LIMITAÇÕES DA REGRESSÃO LINEAR SIMPLES

Altamente Sensível a Outliers:

Um único ponto **discrepante** (um erro de medição ou evento raro) “puxa” toda a reta para **longe** do **comportamento real** do restante dos dados.

LIMITAÇÕES DA REGRESSÃO LINEAR SIMPLES

Impossibilidade de Capturar Ondulações:

Se o comportamento do sistema **sobe** e **desce** (ex.: temperatura ao longo do dia), a reta simples apenas traçará uma **média** horizontal inútil.

REGRESSÃO LINEAR MÚLTIPLA

O mundo real é **multivariado**. Usamos **duas** ou **mais** variáveis de **entrada** para prever o valor de **saída**.

$$y = b_0 + b_1 * x_1 + b_2 * x_2 + \dots + b_n * x_n$$

Exemplo: Prever consumo de combustível considerando **Peso** (**x₁**), **Cilindrada** (**x₂**) e **Pressão dos Pneus** (**x₃**).

REGRESSÃO LINEAR MÚLTIPLA

Como curvar uma reta sem mudar a lógica do modelo? Elevamos as variáveis de entrada a **potências** (x^2, x^3):


$$f(x) = b_0 + b_1x + b_2x^2 + b_3x^3$$

Resultado: A função ganha **flexibilidade** para se **curvar** e **acompanhar** acelerações, parábolas ou desacelerações do processo real.

REGRESSÃO LINEAR MÚLTIPLA

Visualização: Em vez de uma **linha** em um gráfico **plano**, o modelo cria uma **superfície/plano multidimensional**.

REGRESSÃO LINEAR MÚLTIPLA



REGRESSÃO LINEAR MÚLTIPLA

Prever o Consumo de Combustível (y , em km/L) considerando o **Peso** do Veículo (x_1 , em toneladas) e a **Potência** do Motor (x_2 , em CV).

REGRESSÃO LINEAR MÚLTIPLA

Função Resultante do Treinamento:

$$f(x_1, x_2) = 25 - 4 * x_1 - 0,05 * x_2$$

REGRESSÃO LINEAR MÚLTIPLA

Cenário de Inferência:

Chega ao laboratório um novo veículo com
Peso = 2,0 t (x_1) e Potência = 100 CV (x_2).

Cálculo da Inferência:

$$f(2,0; 100) = 25 - 4(2,0) - 0,05(100)$$
$$f(2,0; 100) = 25 - 8 - 5 = 12 \text{ km/L}$$

KNN REGRESSOR

- Na **Classificação**: O modelo busca os K vizinhos mais **próximos** e faz uma **votação** majoritária (a classe mais frequente vence).
- Na **Regressão**: O modelo busca os K vizinhos mais **próximos** e calcula a **média** simples de seus valores numéricos.

KNN REGRESSOR

Exemplo Prático (Previsão de Nota com $K=3$):

Novo Aluno:

Estudou 5 horas. Qual será a nota prevista?

KNN REGRESSOR

Vizinho	Horas de Estudo	Nota Final
.....		
Vizinho 1	4.8 h	70
Vizinho 2	5.1 h	75
Vizinho 3	5.2 h	80

KNN REGRESSOR

Previsão do Modelo: Média das notas dos 3 vizinhos

$$(70 + 75 + 80) / 3 = 75$$

ÁRVORE DE DECISÃO PARA REGRESSÃO

- Na **Classificação**: As decisões nos nós buscam **separar** as **classes**. A folha final entrega uma **categoria**.
- Na **Regressão**: As decisões buscam **agrupar** dados numéricos **parecidos**. A folha final entrega a média dos dados de treino que caíram ali.

ÁRVORE DE DECISÃO PARA REGRESSÃO

Como os Elementos são Selecionados para
Cada Folha?

ÁRVORE DE DECISÃO PARA REGRESSÃO

O algoritmo testa **divisões** (perguntas condicionais) nas variáveis de entrada (ex.: $x_1 < 50 \text{ m}^2$).

Todos os dados de treino que atendem ao **caminho de regras** caem na **mesma folha** final.

ÁRVORE DE DECISÃO PARA REGRESSÃO

Critério de Seleção:

Escolhe a divisão que **minimiza** a variância (ou MSE) dentro dos **grupos** resultantes, fazendo com que dados com valores de y **semelhantes** fiquem na mesma **folha**.

ÁRVORE DE DECISÃO PARA REGRESSÃO

Regra da Árvore:

Experiência > 5 anos? (Se SIM, vá para a Folha A).

ÁRVORE DE DECISÃO PARA REGRESSÃO

Desenvolvedores na Folha A (> 5 anos)	Salário (R\$)
Dev 1	9.000
Dev 2	10.000
Dev 3	11.000

ÁRVORE DE DECISÃO PARA REGRESSÃO

Previsão do Modelo: Para qualquer novo dev com 6 anos de experiência que caia na Folha A:
 $(9000 + 10000 + 11000) / 3 = 10.000$

ÁRVORE DE DECISÃO PARA REGRESSÃO

Estrutura Treinada da Árvore:

Pergunta 1: Área $> 50 \text{ m}^2$?

- SIM $\rightarrow$ Folha A (Contém imóveis com média de preço = RS 250.000)
- NÃO $\rightarrow$ Pergunta 2: Tem garagem?
 - SIM $\rightarrow$ Folha B (Média dos imóveis da folha = RS 180.000)
 - NÃO $\rightarrow$ Folha C (Média dos imóveis da folha = RS 130.000)

ÁRVORE DE DECISÃO PARA REGRESSÃO

Executando a Inferência:

Novo Imóvel:

Área = 40 m², Tem garagem = SIM.

Caminho:

Pergunta 1 [NÃO] → Pergunta 2 [SIM] → Folha B.

- Previsão Final: R\$ 180.000,00.

RANDOM FOREST REGRESSOR

Na Classificação: Combina dezenas de árvores de decisão. Cada árvore "vota" em uma classe e a maioria vence (Moda).

Na Regressão: Combina dezenas de árvores de regressão. Cada árvore prevê um valor numérico e o modelo final calcula a média de todas as previsões.

RANDOM FOREST REGRESSOR

Exemplo Prático (Produção de Milho em Sacas/Hectare):

- Cenário: Uma fazenda submete seus dados de **chuva** e **fertilizante** para uma Random Forest com 3 árvores.

RANDOM FOREST REGRESSOR

Árvore	Previsão Individual
Árvore 1	120 sacas
Árvore 2	115 sacas
Árvore 3	134 sacas

RANDOM FOREST REGRESSOR

Previsão Final da Floresta:

Média das previsões das 3 árvores $(120 + 115 + 134) / 3 = 123$ sacas por hectare.

Modelo	Como Constrói a Resposta em Regressão?	Formato da Função / Fronteira
Regressão Linear	Calcula coeficientes globais via equação (b_0 , b_1).	Reta, Plano ou Curva Polinomial.
KNN Regressor	Média dos valores dos K pontos mais próximos no espaço.	Adaptável localmente por vizinhança.
Árvore de Decisão	Agrupa elementos por menor variância e calcula a média do nó folha.	Função constante por partes (degraus).
Random Forest	Média das estimativas contínuas de dezenas de árvores.	Curva não-linear suave e de alta precisão.

DÚVIDAS???