CIÊNCIA DE DADOS

AVALIAÇÃO DE MODELOS DE APRENDIZADO DE MÁQUINA

MARCOS.EMILIANO@CEFETMG.BR
MARCOS EMILIANO

CENTRO FEDERAL DE EDUCAÇÃO
TECNOLÓGICA DE MINAS GERAIS

COMO SABER SE UM MODELO É "MELHOR" QUE OUTRO?

Treinar um modelo de Inteligência Artificial é apenas **uma parte** do trabalho. O **verdadeiro desafio** de um engenheiro ou cientista de dados é responder: este modelo **está pronto** para ser colocado em produção no **mundo real**?

COMO SABER SE UM MODELO É "MELHOR" QUE OUTRO?

Imagine que você desenvolveu **dois algoritmos** para prever **falhas em motores** de aviões:

- O Modelo **A** acerta **90%** das previsões.
- O Modelo **B** acerta **85%** das previsões.

À primeira vista, o Modelo **A** parece **superior**.

COMO SABER SE UM MODELO É "MELHOR" QUE OUTRO?

Mas e se descobrirmos que os **10% de erros** do Modelo **A** ocorrem justamente em **falhas graves** (**falsos negativos**, liberando motores com **defeito**), enquanto os erros do **Modelo B** são apenas **alarmes falsos** em motores saudáveis?

COMO SABER SE UM MODELO É "MELHOR" QUE OUTRO?

A avaliação de modelos serve para:

1. **Quantificar** o desempenho de maneira objetiva e reproduzível.
2. **Entender** o tipo do **erro**, pois **nem todos** os erros têm o **mesmo custo** ou **risco**.
3. **Comparar** diferentes **algoritmos** para selecionar o mais adequado à regra de negócio.

CLASSIFICAÇÃO VS. REGRESSÃO

A escolha das **métricas** de avaliação depende fundamentalmente da **natureza** da variável resposta **y**.

CLASSIFICAÇÃO VS. REGRESSÃO

	CLASSIFICAÇÃO	REGRESSÃO
Saída	Categoria / Discreta	Número / Contínuo
Pergunta	"Qual grupo?"	"Qual o valor?"
Erro	Acertou ou errou o rótulo y?	Erro: Distância/Desvio (y_real - y_estimado)

CLASSIFICAÇÃO VS. REGRESSÃO

Classificação (Decisão Categórica):

O modelo decide uma **classe** (**y** pertendente a {**0**, **1**} ou **y** pertencente a {**C_1**, **C_2**, ..., **C_k**}).

O erro é **binário** em sua **essência**: ou a resposta **coincide** com o rótulo real, **ou não**.

CLASSIFICAÇÃO VS. REGRESSÃO

Regressão (Estimativa Contínua):
O modelo **aproxima** um **valor numérico** (y pertence a R, sendo R os numeros Reais).
Dificilmente o modelo acertará o valor **exato**;
Portanto, o **foco não é** "**acertar ou errar**", mas sim **medir** o tamanho do **desvio** (distância) entre o **valor real** e a **previsão**.

MÉTRICAS PARA MODELOS DE CLASSIFICAÇÃO

A Matriz de Confusão: O Mapa dos Acertos e Erros

Antes de calcular qualquer **métrica numérica**, organizamos as **previsões** em uma **tabela 2x2** comparando a **classe real** com a **classe predita** pelo modelo:

MÉTRICAS PARA MODELOS DE CLASSIFICAÇÃO

	Predito: FALSO (0)	**Predito: VERDADEIRO (1)**
Real: FALSO (0)	Verdadeiro Negativo (VN)(Acerto no caso negativo)	Falso Positivo (FP) (Alarme Falso / Erro Tipo I)
Real: VERDADEIRO (1)	Falso Negativo (FN) (Perigo Oculto / Erro Tipo II)	Verdadeiro Positivo (VP)(Acerto no caso positivo)

PRINCIPAIS MÉTRICAS DE CLASSIFICAÇÃO

Acurácia (Accuracy)
Mede a **proporção geral** de **acertos** entre **todas** as avaliações realizadas.

$$\text{Acurácia} = (VP + VN)/(VP + VN + FP + FN)$$

PRINCIPAIS MÉTRICAS DE CLASSIFICAÇÃO

Cuidado: A **acurácia** pode ser **enganosa** em conjuntos de dados **desbalanceados**. Se **99%** dos pacientes de um hospital são **saudáveis** (0) e **1%** tem uma **doença rara** (1), um **modelo simplório** que responda "**Saudável**" para **todo** mundo terá 99% de **acurácia**, mas será inútil na **prática**.

PRINCIPAIS MÉTRICAS DE CLASSIFICAÇÃO

Precisão (Precision)
Responde à pergunta: "De todas as vezes em que o modelo previu a classe **POSITIVA**, quantas ele **realmente acertou?**"

$$\text{Precisão} = VP / (VP + FP)$$

PRINCIPAIS MÉTRICAS DE CLASSIFICAÇÃO

Precisão (Precision)
Foco: **Minimizar** os **Falsos Positivos.**

Caso de uso: Filtro de **SPAM.** É **melhor** um e-mail de **SPAM** ir para a **caixa de entrada** (Falso Negativo) do que um **e-mail importante** do chefe ser **classificado** como **SPAM** e sumir (Falso Positivo).

PRINCIPAIS MÉTRICAS DE CLASSIFICAÇÃO

Revocação / Sensibilidade (Recall)
Responde à pergunta: "De **todos** os casos que eram **REALMENTE POSITIVOS**, **quantos** o modelo **conseguiu capturar**?"

Revocação = VP/ (VP + FN)

PRINCIPAIS MÉTRICAS DE CLASSIFICAÇÃO

Foco: Minimizar os **Falsos Negativos**.

Caso de uso: **Diagnóstico** de **doenças graves** ou **detecção** de **peças trincadas** em turbinas. É **preferível** dar um **alarme falso** e fazer um **exame confirmatório** (Falso Positivo) do que **mandar** para **casa** um **paciente doente** (Falso Negativo).

PRINCIPAIS MÉTRICAS DE CLASSIFICAÇÃO

F1-Score:
Média harmônica entre a **Precisão** e a **Revocação**. Fornece uma **métrica única equilibrada**, ideal quando há **desbalanceamento** de classes.

F1 = 2 * Precisão * Revocação / (Precisão + Revocação)

PRINCIPAIS MÉTRICAS DE CLASSIFICAÇÃO

$$\textbf{F1 Score} = \frac{2}{\left(\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}\right)}$$

$$\textbf{F1 Score} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

MÉTRICAS PARA MODELOS DE REGRESSÃO

Na **regressão**, avaliamos o "**resíduo**" de cada ponto **i**, definido como a diferença entre o **valor real** observado (y_i) e o valor **estimado** pelo modelo (y'_i):

$$erro_i = y_i - y'_i$$

MÉTRICAS PARA MODELOS DE REGRESSÃO

MAE (Erro Médio Absoluto)
Calcula a **média aritmética** dos **valores absolutos** dos **erros**.

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

MÉTRICAS PARA MODELOS DE REGRESSÃO

Interpretação: Representa o **erro médio** direto na **mesma unidade** da variável **alvo** (ex.: R, kg, m^3/s).

Característica: Trata todos os **erros** de forma **linear** (pouco sensível a outliers).

MÉTRICAS PARA MODELOS DE REGRESSÃO

MSE (Erro Quadrático Médio)
Calcula a média dos quadrados dos erros.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

MÉTRICAS PARA MODELOS DE REGRESSÃO

Característica:
Elevar o **erro** ao **quadrado** elimina valores **negativos** e **penaliza** severamente **grandes desvios**.
A unidade de medida fica ao quadrado (ex.: R^2, kg^2), o que dificulta a interpretação direta.

MÉTRICAS PARA MODELOS DE REGRESSÃO

RMSE (Raiz do Erro Quadrático Médio)
Calcula a **raiz quadrada** do **MSE** para retornar à unidade original da variável de saída.

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

MÉTRICAS PARA MODELOS DE REGRESSÃO

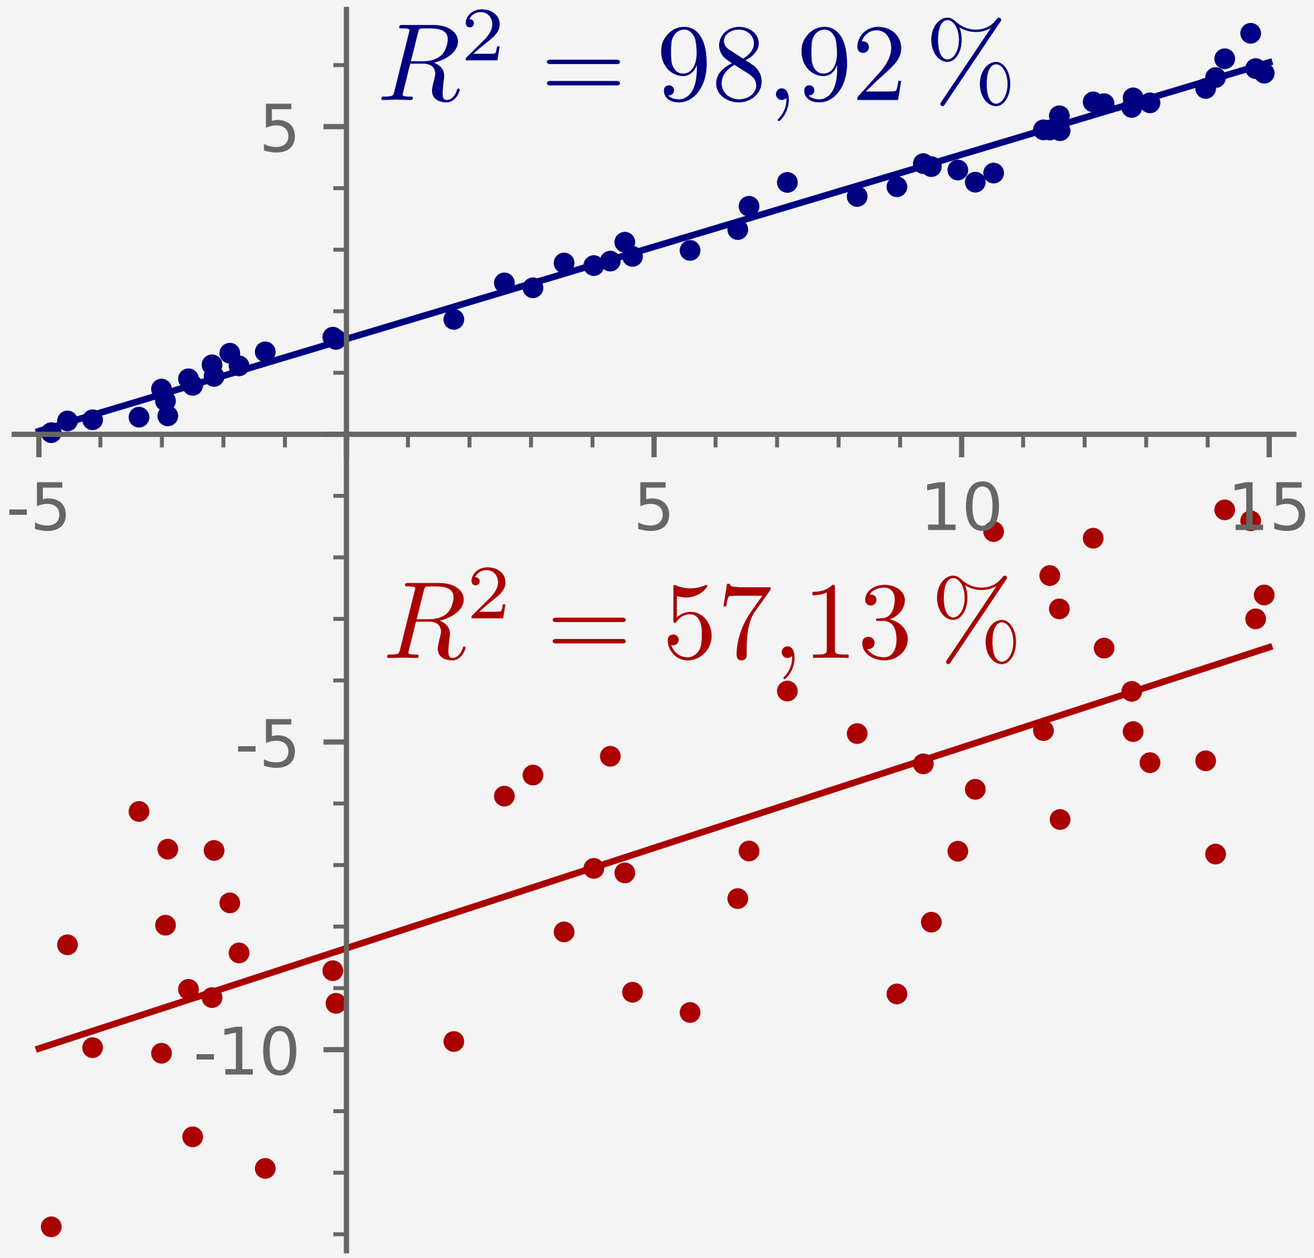
Interpretação: É a métrica **mais utilizada** em aplicações **industriais** e de **engenharia**. Ela **mantém** a **penalidade** para **grandes erros** (herdada do quadrado), mas entrega o resultado na **unidade física real** do problema.

MÉTRICAS PARA MODELOS DE REGRESSÃO

R^2 (Coeficiente de Determinação)
Mede a **proporção** da **variância total** da **variável alvo** que é explicada pelo modelo em relação a um **modelo ingênuo** (que apenas prevê a média y").

MÉTRICAS PARA MODELOS DE REGRESSÃO

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$


$R^2 = 98{,}92\,\%$
$R^2 = 57{,}13\,\%$
5
-5
5
10
15
-5
-10

MÉTRICAS PARA MODELOS DE REGRESSÃO

Interpretação: Varia **tipicamente** de 0 a 1 (ou 0% a 100%):

- $R^2 = 1.0$: O modelo **explica 100%** da **variabilidade** dos dados (previsão perfeita).
- $R^2 = 0.0$: O modelo tem o **mesmo desempenho** que usar a **simples média** dos dados.

DÚVIDAS???