CIÊNCIA DE DADOS

APRENDIZADO NÃO SUPERVISIONADO: AGRUPAMENTO

MARCOS.EMILIANO@CEFETMG.BR
MARCOS EMILIANO

CENTRO FEDERAL DE EDUCAÇÃO
TECNOLÓGICA DE MINAS GERAIS

OBJETIVOS DA AULA

- Aprendizado **Supervisionado** vs. **Não Supervisionado**.
- **Motivações** e **casos de uso** no mundo real.
- O conceito de **Agrupamento** (Clustering).
- Modelos **fundamentais**: K-Means, Agrupamento Hierárquico e DBSCAN

SUPERVISIONADO VS. NÃO SUPERVISIONADO

Aprendizado Supervisionado (O que já vimos):

- Trabalhamos com dados de **entrada** (X) e um **gabarito/rótulo** de saída (y).

Exemplo: Prever se um e-mail é "SPAM" (1) ou "Não SPAM" (0), ou estimar o preço de uma casa em R$.

- Os modelos **aprendem** utilizando os **rótulos**, respostar, como **referência** durante o **treinamento**.

SUPERVISIONADO VS. NÃO SUPERVISIONADO

Aprendizado Não Supervisionado:

- Possuímos **apenas** as variáveis de **entrada** (X). Não existe **variável alvo** (y) nem **gabarito**.
- O **objetivo** é fazer o algoritmo **explorar os dados** e encontrar **grupos naturais**, **padrões** ou **regras** ocultas.

Analogia: Receber uma caixa cheia de **peças** sortidas **sem manual** e **organizá-las** em **formato**, **cor** ou **tamanho** por **"intuição"**.

POR QUE USAR APRENDIZADO NÃO SUPERVISIONADO?

Rotular dados é **caro** e **demorado**:

- No mundo real, **90%** dos dados coletados **não possuem rótulo**. Contratar especialistas para **classificar milhões de dados** é **inviável**.

POR QUE USAR APRENDIZADO NÃO SUPERVISIONADO?

Descoberta de padrões desconhecidos:

- O **algoritmo** consegue **identificar comportamentos** que o ser humano nem sabia que existiam.

POR QUE USAR APRENDIZADO NÃO SUPERVISIONADO?

Aplicações Práticas:

- **Segmentação de Clientes:** Agrupar compradores por perfil de consumo para campanhas personalizadas.

POR QUE USAR APRENDIZADO NÃO SUPERVISIONADO?

Aplicações Práticas:

- **Detecção de Fraudes e Anomalias:** Identificar transações bancárias fora do padrão normal.

POR QUE USAR APRENDIZADO NÃO SUPERVISIONADO?

Aplicações Práticas:

- **Compressão de Imagens:** Reduzir o número de cores de uma imagem agrupando pixels de tonalidades parecidas.

O CONCEITO DE AGRUPAMENTO (CLUSTERING)

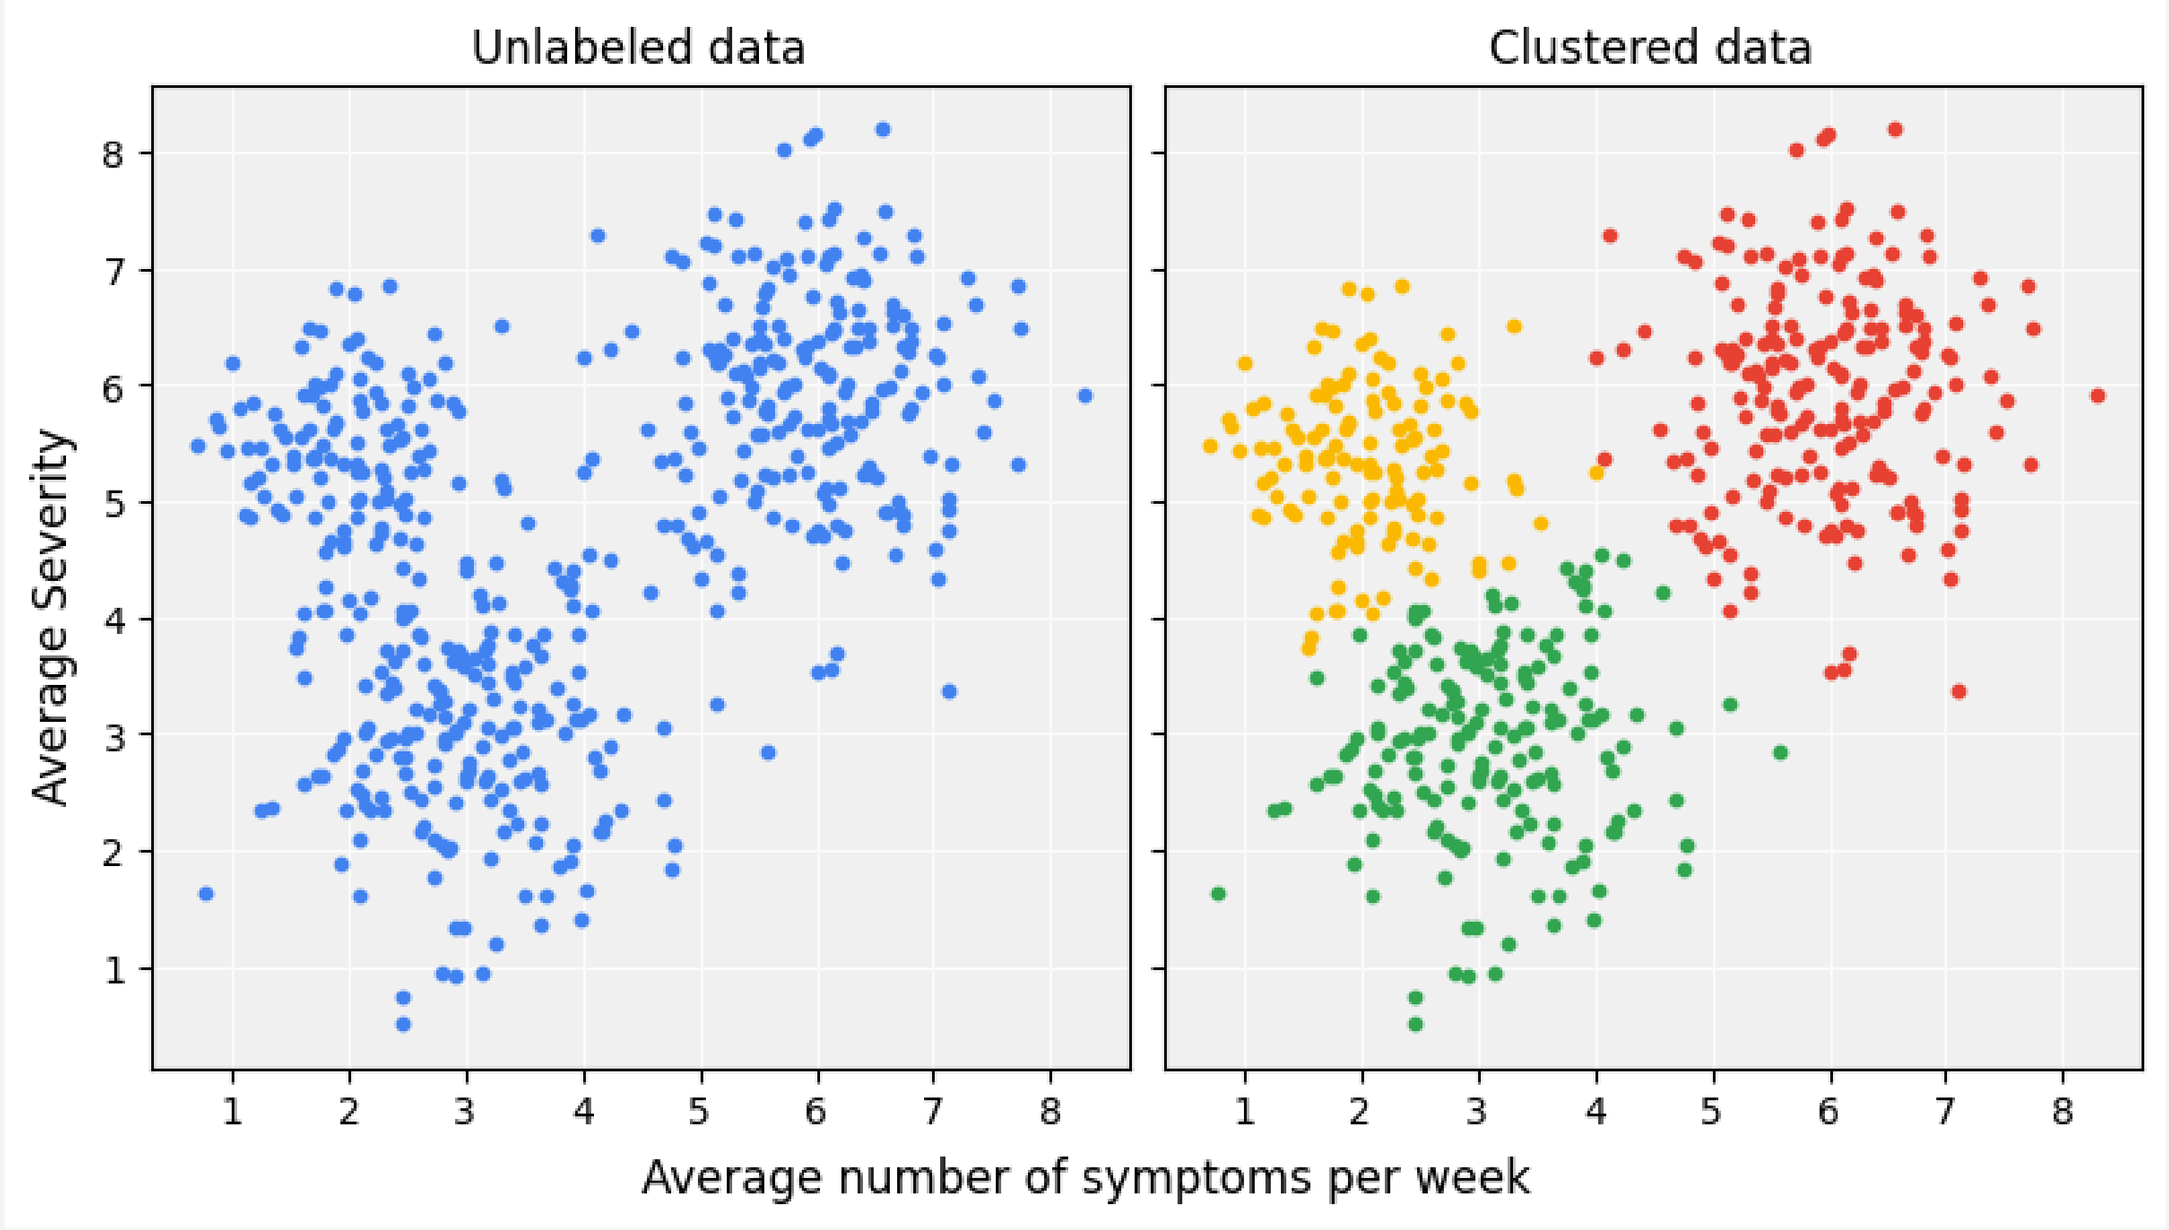
Definição: Técnica que divide os dados em grupos (clusters) de modo que:

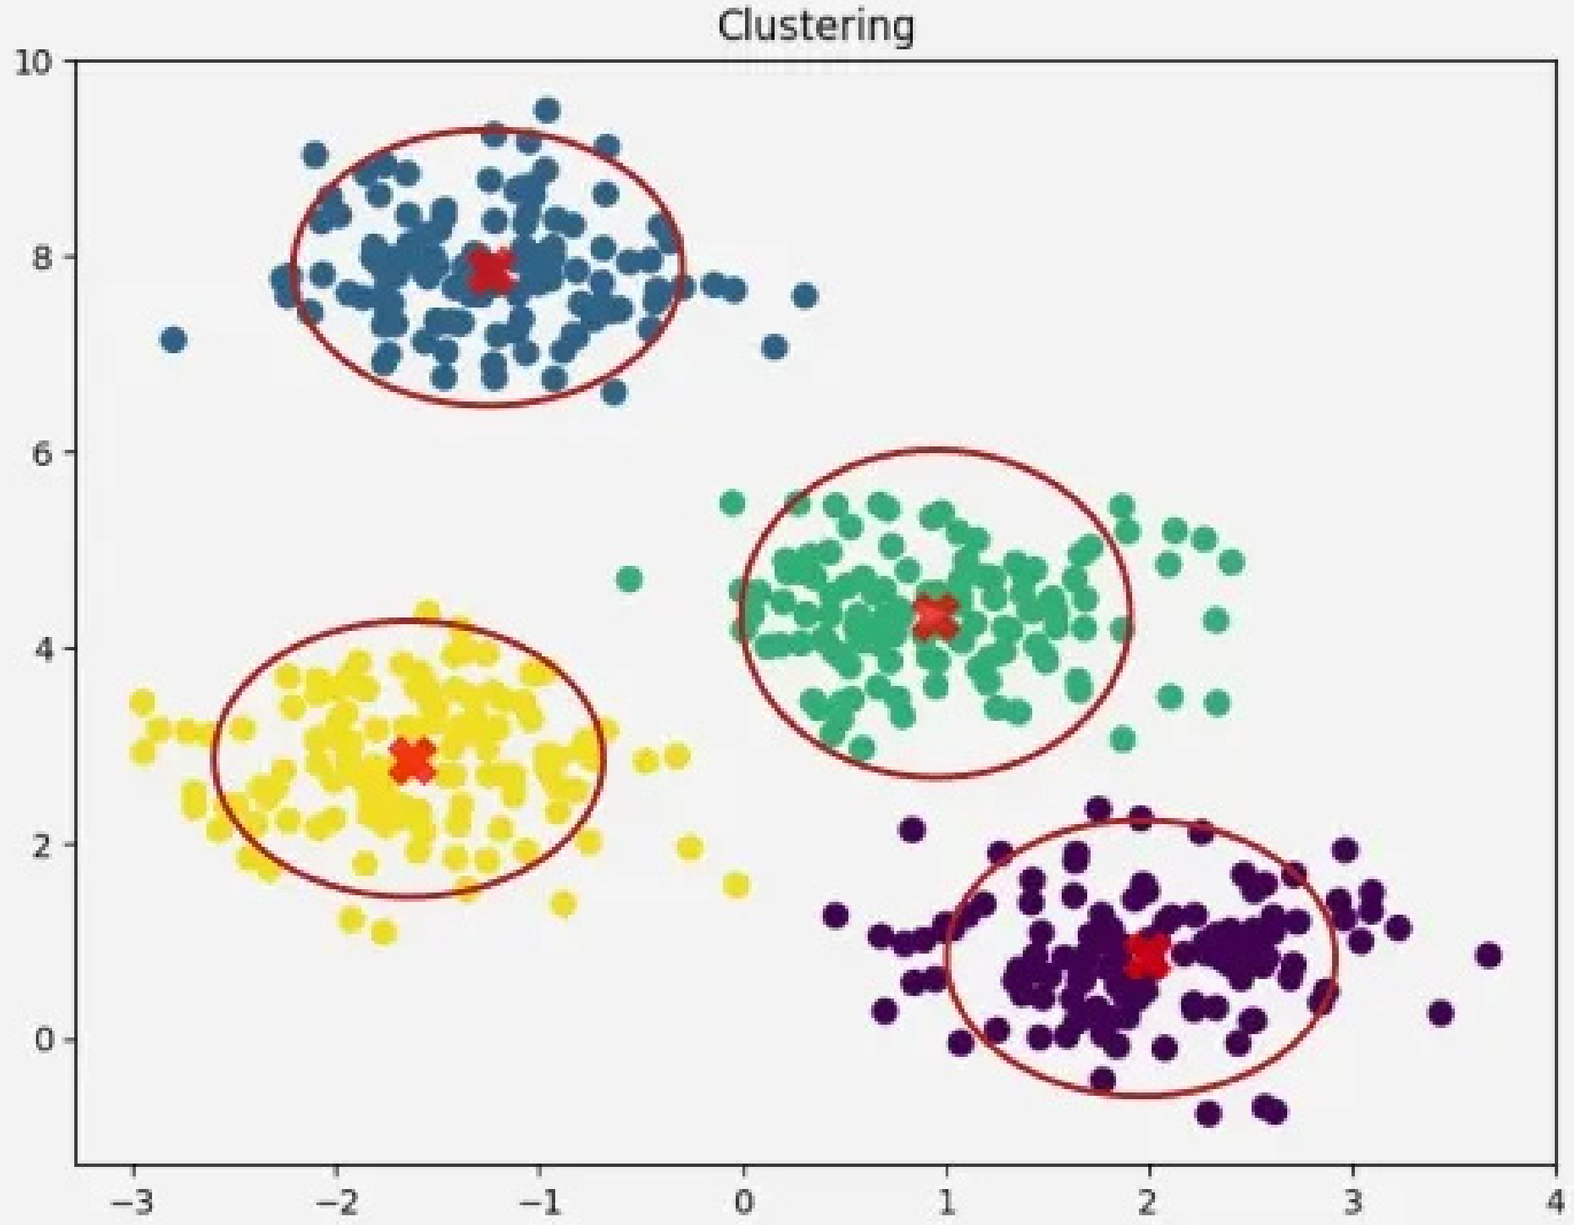
1. **Elementos** do **mesmo grupo** sejam o mais **parecidos** possível **entre si** (alta similaridade interna).
2. **Elementos** de **grupos diferentes** sejam o mais **distintos** possível **entre si** (alta separação).

O CONCEITO DE AGRUPAMENTO (CLUSTERING)

Como medir a semelhança?

- Utiliza-se a **distância geométrica** (como a distância Euclidiana) **entre** os **pontos** no **espaço de características**.


Unlabeled data
Clustered data
Average Severity
Average number of symptoms per week
1
2
3
4
5
6
7
8


Clustering
10
8
6
4
2
0
−3
−2
−1
0
1
2
3
4

K-MEANS (AGRUPAMENTO POR CENTROIDES)

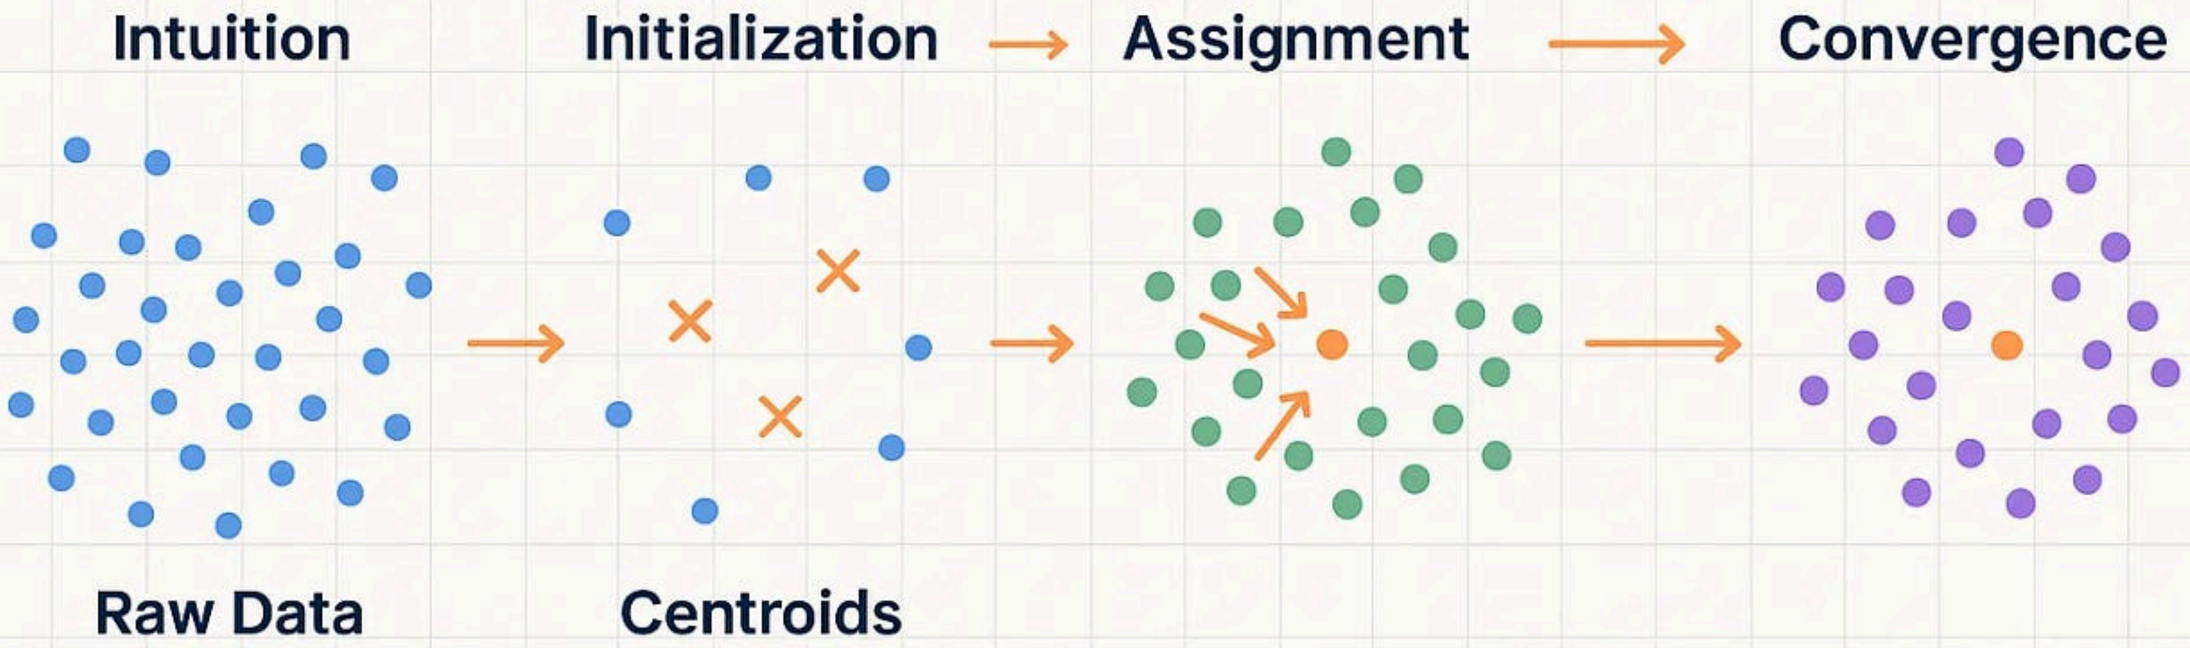
1. Definimos **previamente** o número **K** de **grupos** desejados.
2. O algoritmo **sorteia K** pontos no espaço chamados **Centroides** (centro dos grupos).
3. Cada dado é **atribuído** ao **centroide** mais **próximo**.
4. O algoritmo **recalcula** a **posição** do **centroide** tirando a **média** dos **pontos** de cada **grupo**.
5. **Repete-se** a **atribuição** e a **média** até que os centroides parem de se mover.

K-MEANS (AGRUPAMENTO POR CENTROIDES)

Analogia – Praça de Alimentação:

- Imagine posicionar **K lixeiras** comunitárias em um **grande evento**. Você as **move continuamente até** que cada uma fique **exatamente** no **centro** da **região** onde as **pessoas** mais se **concentram**.

K-MEANS CLUSTERING



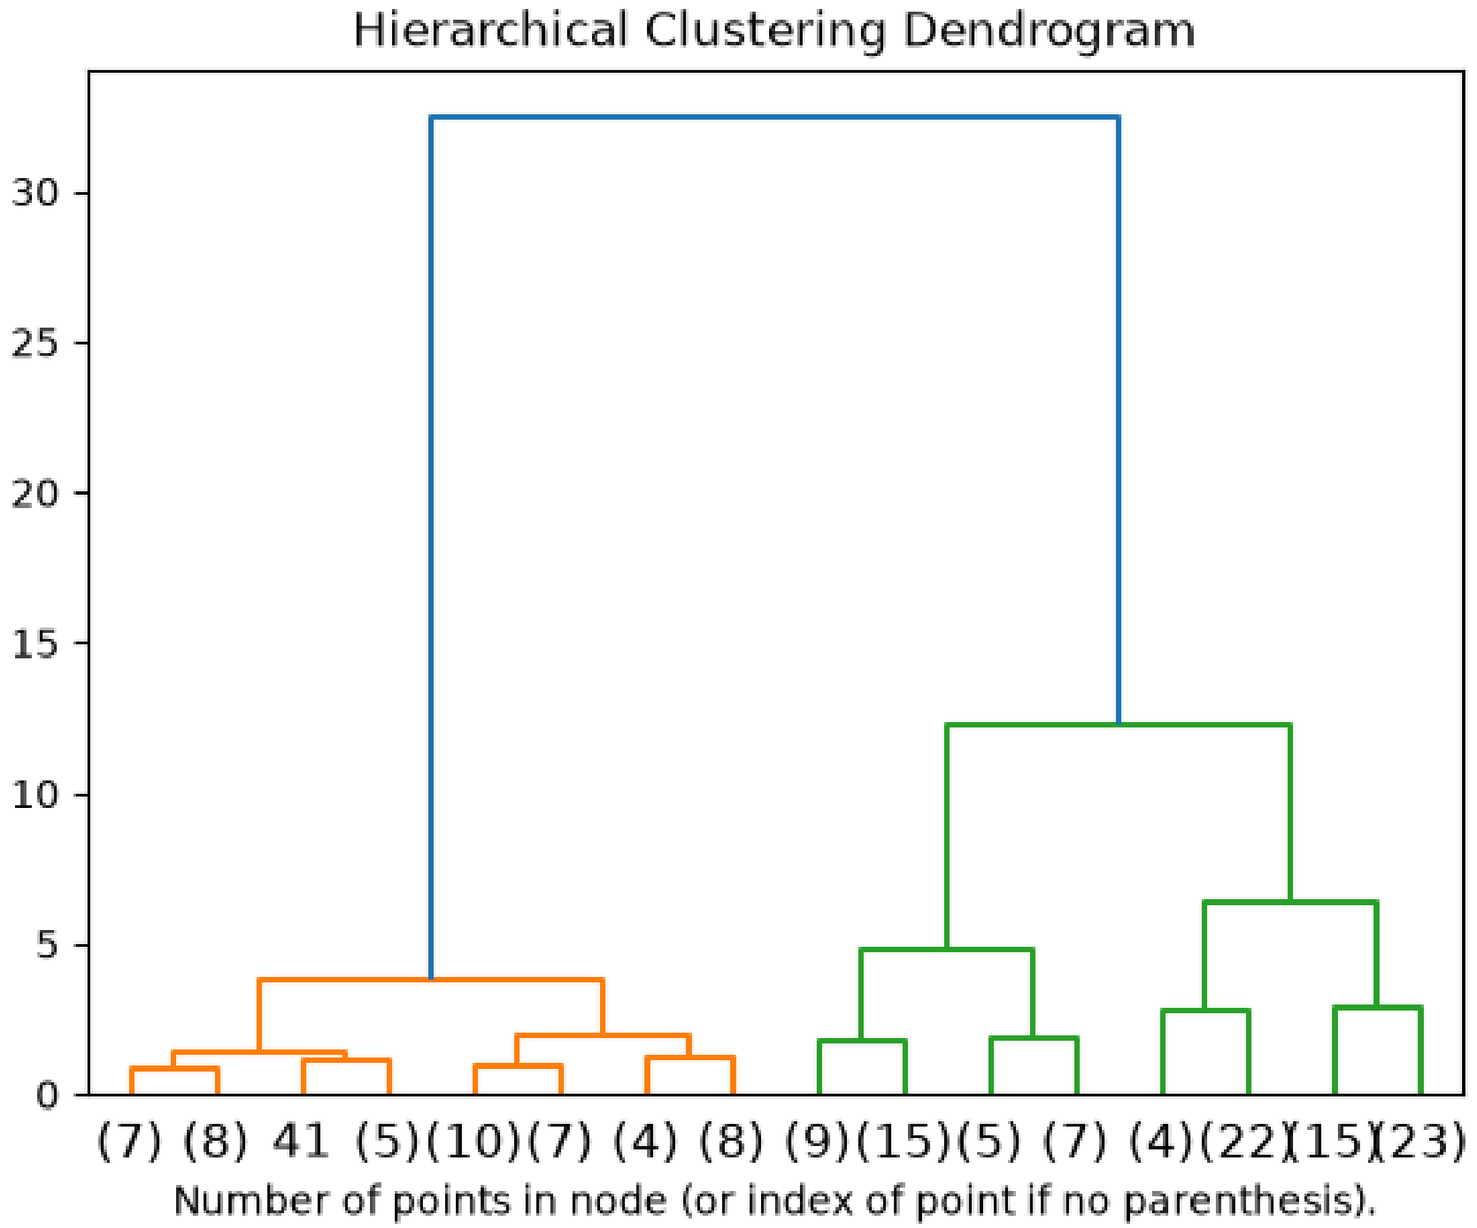
AGRUPAMENTO HIERÁRQUICO

Como Funciona (Abordagem Aglomerativa):

1. Começa **assumindo** que cada ponto é um **grupo individual**.
2. Encontra os **dois pontos** mais **próximos** no espaço e os **funde** em um **único grupo**.
3. **Repete** o processo de **fusão dos grupos** mais próximos **passo a passo**.
4. Para no final, quando **todos os pontos** estiverem **reunidos** em um **único** grande **grupo**.

AGRUPAMENTO HIERÁRQUICO

O Dendrograma:
O **resultado** é visualizado em um **diagrama** em formato de árvore (Dendrograma). Para **escolher** o número de **grupos**, basta **"cortar"** a árvore na **altura desejada**.


Hierarchical Clustering Dendrogram
30
25
20
15
10
5
0
(7) (8) 41 (5)(10)(7) (4) (8) (9)(15)(5) (7) (4)(22)(15)(23)
Number of points in node (or index of point if no parenthesis).

AGRUPAMENTO HIERÁRQUICO

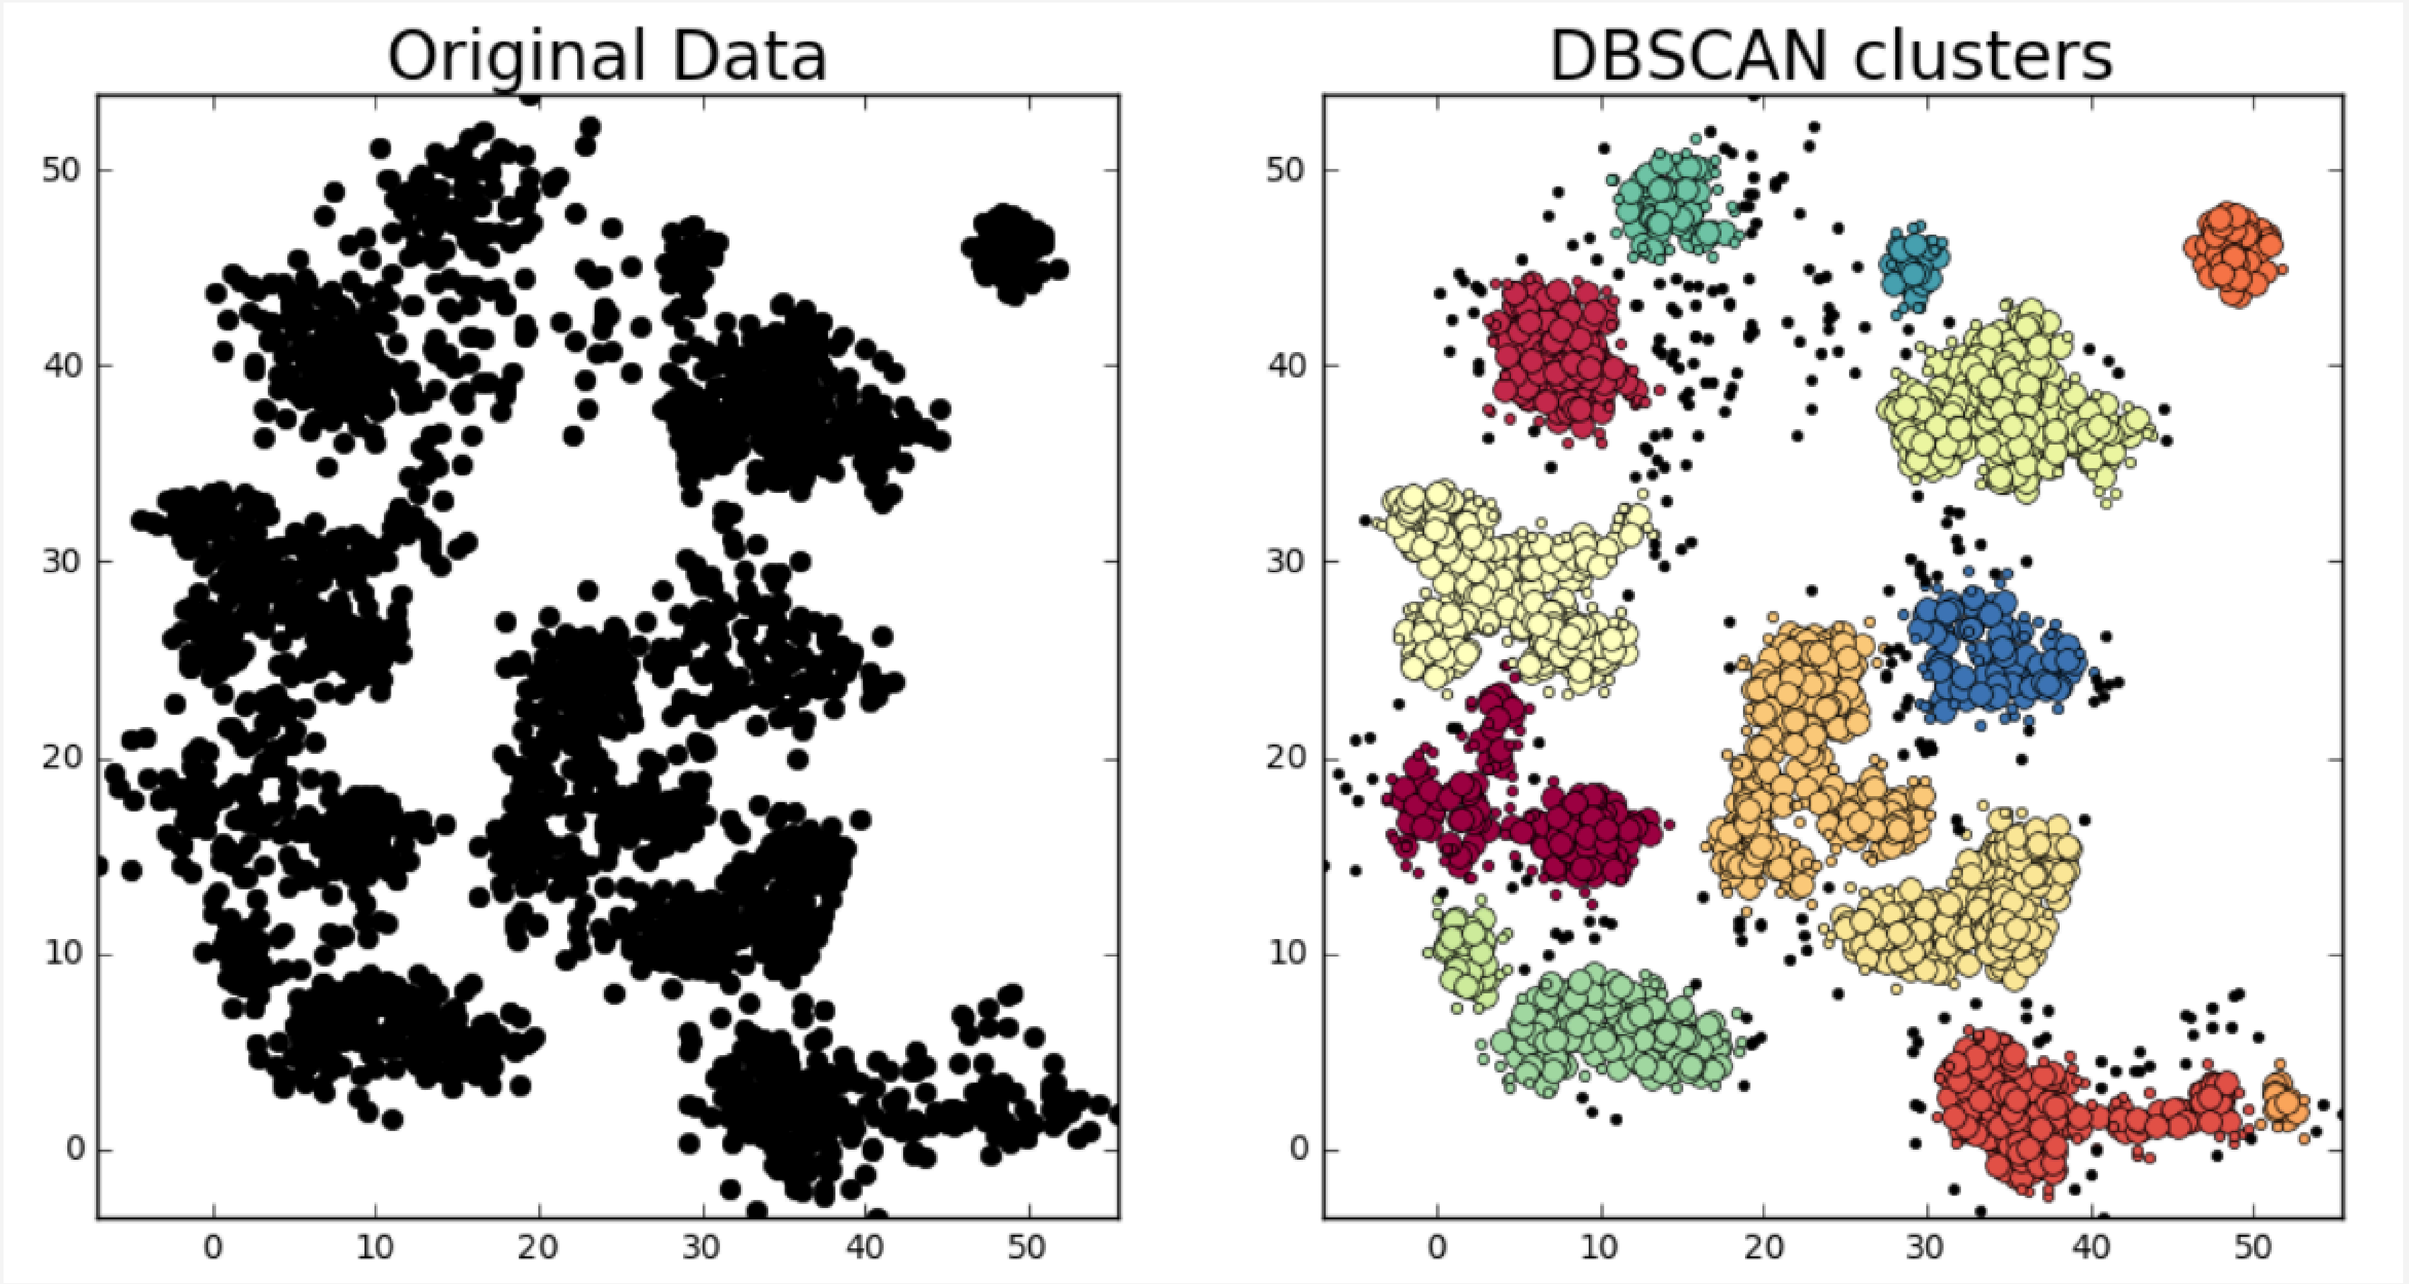
Analogia – A Árvore de Arquivos:
Imagine **organizar** os **arquivos** de um **computador**: primeiro você junta **fotos** do **mesmo dia**, depois cria a pasta "**Viagens**", que fica dentro da pasta "**Fotos Pessoais**", até chegar na **raiz do sistema**.

DBSCAN (AGRUPAMENTO POR DENSIDADE)

1. Procura por **regiões** no **espaço** onde existe uma **alta densidade** de **pontos próximos**.
2. Se uma região tem **pontos suficientes aglomerados**, ela vira um **cluster**.
3. **Pontos isolados** que não possuem **vizinhos suficientes** são classificados como **Ruído / Outliers** (não são forçados a entrar em nenhum grupo).

DBSCAN (AGRUPAMENTO POR DENSIDADE)

Analogia –Mapa de Luzes Noturnas:
Em um **mapa** visto de **satélite à noite**, as **grandes cidades** aparecem como **manchas brilhantes** e **densas** (grupos).
Fazendas isoladas com apenas **uma luz** acesa no meio do nada **não são cidades** e nem **pertencem** a nenhuma delas (ruído/outliers).


Original Data
DBSCAN clusters
0
10
20
30
40
50

Modelo	Vantagens Principais	Limitações
K-Means	**Simples**, extremamente **rápido** e **funciona** bem para **grandes volumes** de dados.	**Exige definir** o número **K** com antecedência; só encontra **grupos esféricos/circulares**.
Hierárquico	**Não** exige **definir** o **número** de **grupos** antes; gera o Dendrograma visual.	Computacionalmente **pesado** para **bases** de dados muito **grandes**.
DBSCAN	Encontra grupos de qualquer **formato** (curvos, anéis); **isola ruídos/outliers**.	**Sensível** ao **ajuste** de **parâmetros** de **distância** e **densidade**.

DÚVIDAS???