

Disciplina: Ciência de Dados

Professor: Marcos Emiliano

Centro Federal de Educação Tecnológica de Minas Gerais - Departamento de Computação

Objetivo Geral

O trabalho prático da disciplina de **Ciência de Dados** tem como objetivo **consolidar os conceitos teóricos** por meio da resolução de um **problema analítico real**. O projeto será desenvolvido em **duplas** e dividido em **três entregas incrementais**. Espera-se a utilização da linguagem **Python**, bem como das bibliotecas abordadas em sala (Pandas, NumPy, Matplotlib, Seaborn e Scikit-Learn) por meio de **Jupyter Notebooks** (preferencialmente Google Colab).

Todas as entregas deverão ser realizadas exclusivamente no formato de **notebook Python** (.ipynb). Os conteúdos textuais (análises, justificativas e conclusões) e práticos (códigos e visualizações) devem estar integrados no mesmo arquivo, não havendo a necessidade de gerar documentos PDF ou de texto dedicados. Para a segunda e terceira entregas, que incluirão apresentações em sala de aula, a produção de slides não é obrigatória; o próprio notebook poderá ser utilizado como suporte visual para guiar a apresentação.

Etapa 1: Definição do Problema, Base de Dados e Fundamentação Teórica - 11/09

Objetivo: Estabelecer o domínio do problema, justificar sua importância e definir claramente o que será modelado.

Entregáveis Esperados:

1. **Tema e Contextualização:** Definição clara do domínio do problema (ex: saúde, finanças, metalurgia, varejo). Qual é a pergunta de pesquisa ou o problema de negócios que o projeto visa resolver?
2. **Descrição Breve dos Dados:** Identificação da base de dados selecionada (recomenda-se a plataforma Kaggle). Deve incluir a origem dos dados, o número estimado de instâncias (linhas) e atributos (colunas), e a definição do que cada registro representa.

3. **Relevância e Justificativa:** Por que a resolução deste problema é importante? Quais os impactos positivos (científicos, econômicos ou sociais) que a descoberta de conhecimento nesta base pode trazer?
4. **Trabalhos Relacionados:** Pesquisa de, no mínimo, dois artigos científicos, repositórios ou projetos similares que já tentaram resolver o mesmo problema ou utilizaram a mesma base de dados. Descrever brevemente as abordagens utilizadas por eles.
5. **Objetivo do Modelo:** Definição formal da tarefa de Aprendizado de Máquina. O problema trata-se de Classificação, Regressão ou Agrupamento (Clustering)? Qual é a variável alvo (target) a ser prevista (se aplicável)?

Etapa 2: Organização, Descrição e Tratamento dos Dados

15/10

Objetivo: Realizar a Análise Exploratória de Dados (EDA) e aplicar técnicas de pré-processamento para garantir a qualidade da informação que alimentará os algoritmos.

Entregáveis Esperados:

1. **Análise Exploratória de Dados (EDA):**
 - Geração de estatísticas descritivas básicas (média, mediana, desvio padrão, valores mínimos e máximos) para os atributos numéricos.
 - Visualização da distribuição da variável alvo (para verificar, por exemplo, se há desbalanceamento de classes).
 - Geração de gráficos explicativos (histogramas, boxplots, gráficos de dispersão) que evidenciem correlações preliminares ou o comportamento das variáveis.
2. **Limpeza de Dados (Data Cleaning):**
 - Identificação e tratamento de valores ausentes (Nulos/NaN). Explicar a estratégia adotada (ex: remoção da linha, preenchimento com a média ou mediana).
 - Identificação e tratamento de outliers (valores anômalos que possam distorcer o aprendizado).
3. **Transformação de Dados:**
 - Codificação de variáveis categóricas (Encoding). Transformação de atributos em texto (ex: "Sim"/"Não", "Masculino"/"Feminino") para formatos numéricos aceitos pelos modelos.
 - Escalonamento/Normalização: Aplicação de técnicas para colocar variáveis numéricas em uma mesma escala, evitando que atributos com valores absolutos maiores dominem o aprendizado.

4. **Seleção de Atributos (Feature Engineering/Selection):**

- Justificativa para a manutenção ou descarte de colunas. Quais atributos realmente fazem sentido para a lógica do problema? (Evitar a "Maldição da Dimensionalidade").

Etapa 3: Aplicação de Modelos e Descoberta de Conhecimento 27/11

Objetivo: Treinar modelos de aprendizado de máquina, avaliar seus desempenhos de forma rigorosa e extrair o conhecimento gerado.

Entregáveis Esperados:

1. **Particionamento dos Dados:**

- Divisão do dataset em conjuntos de Treinamento e Teste (ex: 80% / 20% ou 70% / 30%), garantindo que a avaliação seja feita em dados não vistos pelo modelo durante o ajuste.

2. **Treinamento de Modelos (Base e Avançado):**

- Implementação de pelo menos dois modelos simples como base de comparação (Baseline). Ex: k-NN para classificação ou Regressão Linear Simples para regressão.
- Implementação de pelo menos dois modelos mais complexos. Ex: Árvores de Decisão (Decision Trees), Random Forest ou Naive Bayes.

3. **Avaliação de Desempenho (Score e Métricas):**

- Para Classificação: Apresentar a Acurácia, Matriz de Confusão, Precisão (Precision) e Revocação (Recall).
- Para Regressão: Apresentar métricas de erro como o Erro Quadrático Médio (MSE ou RMSE) e o Coeficiente de Determinação (R^2).

4. **Análise Crítica e Conclusões:**

- Qual modelo obteve o melhor desempenho e por quê?
- Houve indícios de Overfitting (memorização excessiva) ou Underfitting (incapacidade de aprender os padrões)?
- Quais atributos se mostraram mais importantes para as predições da máquina?
- **Descoberta de Conhecimento:** O que o grupo aprendeu sobre o problema inicial após aplicar os modelos? A hipótese levantada na Etapa 1 foi confirmada ou refutada pelas evidências empíricas geradas pelo algoritmo?